

Cartes virtuelles pour l'exploration autonome d'environnements sous-marins encombrés

Jinkun Wang, Fanfei Chen, Yewei Huang, John McConnell, Tixiao Shan,
et Brendan Englot, Membre senior, IEEE

Résumé—

Nous considérons le problème de mobilité autonome l'exploration robotique dans un environnement inconnu, en tenant compte du taux de couverture du robot, de l'incertitude de la carte et de l'incertitude de l'estimation d'état. Cet article présente un cadre d'exploration novateur pour les robots sous-marins opérant dans des environnements encombrés, basé sur la localisation et la cartographie simultanées (SLAM) avec sonar d'imagerie. Le système proposé comprend la génération de trajectoires, la prévision de la reconnaissance des lieux, la propagation des croyances

et évaluation de l'utilité utilisant une carte virtuelle, qui estime l'incertitude associée aux cellules de carte dans tout l'espace de travail du robot. Nous évaluons les performances de ce cadre dans des expériences simulées, montrant que notre algorithme conserve un taux de couverture élevé pendant l'exploration tout en maintenant une faible erreur de cartographie et de localisation. L'applicabilité dans le monde réel de notre cadre est également démontrée sur un véhicule téléopéré sous-marin (ROV) explorant un environnement portuaire.

Mots-clés — Véhicules sous-marins autonomes (AUV), planification de mouvement, localisation et cartographie simultanées, navigation par sonar.

I. INTRODUCTION

La localisation et la cartographie simultanées (SLAM) ont été largement étudiées en théorie et appliquées avec succès sur des plateformes de détection réelles pour l'estimation d'état et la construction de cartes à partir de données collectées passivement [1]. Cependant, il reste difficile pour un véhicule autonome de cartographier activement un environnement inconnu, gérant correctement le compromis entre la vitesse d'exploration et la qualité de l'estimation d'état. Améliorer la capacité d'exploration autonome est bénéfique pour de nombreuses tâches de cartographie robotique, en particulier dans des scénarios où la téléopération est limitée ou irréalisable en raison d'une communication contrainte, par exemple dans des environnements subsea inconnus avec des robots sous-marins.

Le problème d'exploration autonome est généralement résolu en trois étapes : génération de trajectoires, évaluation de l'utilité et exécution. Premièrement, nous identifions des points de passage candidats ou générons une séquence d'actions à suivre, ce qui est généralement réalisé en énumérant des limites ou en utilisant des méthodes de planification de trajectoires basées sur l'échantillonnage. Le chemin sélectionné est généralement simple.

Ce travail a été soutenu par une subvention de Schlumberger Technology Corporation, et par la National Science Foundation, bourses IIS-1652064 et IIS-1723996. (Auteur correspondant : Brendan Englot.)

Y. Huang, J. McConnell et B. Englot sont au Département de Génie Mécanique, Stevens Institute of Technology, Hoboken, NJ, États-Unis (courriel : {yhuang85, jmconn1, benglot}@stevens.edu).

J. Wang était précédemment au Stevens Institute of Technology et est maintenant chez Amazon Robotics, Louisville, CO, États-Unis. (courriel : me.jkunw@gmail.com).

F. Chen était précédemment au Stevens Institute of Technology et est maintenant chez Exyn Technologies, Philadelphia, PA, États-Unis. (courriel : franky-cff@gmail.com).

T. Shan était auparavant au Stevens Institute of Technology et est maintenant chez SRI International, Princeton, NJ, États-Unis. (courriel : tixiao.shan@sri.com).

à exécuter à l'aide de contrôleurs à rétroaction, ce qui nous laisse un problème fondamental de conception d'une fonction d'utilité pour mesurer l'optimalité du trajet. Essentiellement, elle doit capturer le dilemme d'exploration-exploitation, c'est-à-dire l'équilibre entre visiter des zones inconnues pour réduire l'incertitude de la carte, et revisiter des zones connues pour améliorer la localisation et l'exactitude de la carte.

Prévoir l'impact des actions futures sur l'incertitude du système reste un problème ouvert [1], et cela est particulièrement vrai pour les repères non observés ou d'autres caractéristiques environnementales qui peuvent fournir des mesures relatives utiles. Nos travaux précédents sur l'exploration par maximisation de l'espérance (EM) [2] ont introduit le concept d'une carte virtuelle composée de repères virtuels agissant comme proxy d'une carte réelle basée sur des caractéristiques, sur laquelle nous pouvons prédire l'incertitude résultant des actions de détection futures. Étant donné que chaque repère virtuel est profondément lié aux poses robot qui peuvent l'observer, les métriques d'exploration et de localisation sont unifiées comme le déterminant de la matrice de covariance d'erreur des repères virtuels. Dans les travaux ultérieurs [3], nous avons envisagé un scénario de navigation dense plus réaliste, dans lequel l'exploration avec des robots terrestres équipés de lidar doit s'appuyer sur le SLAM de pose qui n'incorpore pas des caractéristiques énumérées explicitement. Dans ce scénario, SegMap [4], [5] a fourni une utilité pratique pour la reconnaissance des lieux. Les segments de carte servaient de repères, et les fermetures de boucle à partir de l'appariement de segments nous ont permis d'effectuer une localisation active de manière efficace.

Dans cet article, nous étendons les algorithmes d'exploration EM utilisés dans les travaux antérieurs [2], [3] à l'application du monde réel qui a initialement inspiré ce travail - l'exploration d'environnements sous-marins encombrés par un robot équipé d'un sonar d'imagerie multi-faisceaux. Ce faisant, cet article apporte les contributions suivantes :

- Une exposition substantiellement plus détaillée des processus de propagation des croyances (sur les actions candidates du robot et sur les repères virtuels) qui soutiennent l'implémentation efficace de l'exploration EM en temps réel, à grande échelle, (ces sujets ne sont discutés que brièvement dans [3]);
- Une architecture pour un SLAM sous-marin robuste et une cartographie des occupancies avec sonar d'imagerie capable de soutenir une planification et une prise de décision en temps réel répétées sur leurs estimations évolutives dans des environnements encombrés ;
- Une évaluation approfondie des performances de notre cadre dans des environnements simulés, évaluant rigoureusement le compromis entre le taux d'exploration d'un robot, la localisation et l'exactitude de la carte par rapport à d'autres algorithmes ;
- La première instance, à notre connaissance, d'exploration autonome d'un environnement extérieur réel, rempli d'obstacles, dans lequel un robot sous-marin (un BlueROV monoxypié relié que nous utilisons comme système de démonstration) dis-

intègre directement son processus SLAM et les prédictions basées sur ce processus dans sa prise de décision.

II. TRAVAUX CONNEXES

Les différents facteurs pris en compte dans notre problème d'exploration de robot mobile, l'incertitude de localisation, l'incertitude de la carte et le taux de couverture, ont été considérés individuellement et en combinaison dans un grand nombre de travaux antérieurs. Pour gérer l'incertitude de la carte, la planification avec des cartes a priori a été utilisée pour minimiser activement l'incertitude des repères connus [6], [7], [8]. De même, la planification dans des environnements inconnus mais avec des points de passage prédéfinis est étudiée dans [9]. Si l'on ne considère pas l'incertitude de l'état et de la carte du robot, le problème a été abordé en suivant la frontière la plus proche [10], en choisissant des actions de détection pour maximiser l'information mutuelle [11], [12], en utilisant l'information mutuelle quadratique de Cauchy-Schwarz (CSQMI) pour réduire le temps de calcul [13], et en explorant sur des cartes de frontière de processus gaussiens continus [14]. Explorer efficacement sur différentes distances a été réalisé en fournissant au robot des options gourmandes et non gourmandes [15], ainsi qu'en planifiant sur un horizon glissant où les robots n'exécutent qu'une petite partie de chaque plan avant de replanifier [16]. La plupart des recherches existantes sur l'exploration dans des environnements inconnus tirent parti des cartes de grille d'occupation, en considérant des fonctions d'utilité impliquant l'entropie de la carte et l'incertitude de la pose du robot [17], [18]. Ce paradigme a réussi dans des applications complexes, y compris l'exploration 3D en temps réel et la cartographie de structures avec des micro-véhicules aériens [19]. Cependant, une estimation d'état inexacte est susceptible de produire une carte complète mais déformée, quel que soit la vitesse d'exploration. La corrélation entre la localisation et le gain d'information est souvent prise en compte en intégrant sur l'entropie de la carte pondérée par l'incertitude de la pose [20], [21], [22]. Cependant, dans des travaux antérieurs, nous avons montré que l'entropie pondérée ne parvient pas à capturer l'erreur d'estimation des repères existant sur la carte, et des inexactitudes de la carte peuvent en résulter [2].

Un ensemble de travaux relativement récents a examiné l'exploration autonome et la perception active avec des robots sous-marins en particulier. Ces travaux ont mis l'accent sur la cartographie avec sonar, qui peut percevoir des obstacles à des distances relativement longues dans tous types d'eau. Vidal et al. [23] ont d'abord utilisé la cartographie d'occupation basée sur le sonar, en 2D, pour explorer des environnements sous-marins encombrés avec un véhicule sous-marin autonome (AUV), qui sélectionne à plusieurs reprises des points de vue proches aux frontières de la carte. Des travaux ultérieurs de Palomeras et al. [24] ont étendu l'approche à la cartographie et à l'exploration 3D basées sur le sonar d'environnements sous-marins encombrés en utilisant un cadre next-best-view qui pondère la distance de déplacement, les frontières et le suivi de contour lors de la sélection d'un nouveau point de vue. En plus de la planification de vues, le SLAM actif a été appliqué aux robots sous-marins, utilisé pour intégrer des détours planifiés dans des inspections visuelles permettant de réaliser des fermetures de boucle [25], [26], [27], et pour dévier de la planification next-best-view basée sur le sonar 3D afin de réaliser une fermeture de boucle lorsque l'incertitude de localisation dépasse un seuil désigné [28]. Parmi ces deux travaux, le premier navigue à une distance fixe de la surface de la coque d'un navire, et le second explore et cartographie un environnement de réservoir intérieur.

Enfin, il convient également de noter que l'exploration autonome de robots mobiles est liée à un ensemble de travaux plus larges qui étudient la planification dans l'espace de croyance (BSP) dans des environnements inconnus. Ces travaux ont réussi à assouplir les hypothèses souvent imposées à l'exploration, telles que celle des observations de vraisemblance maximale [9], et à obtenir une propagation de croyance et une récupération de covariance plus efficaces [29]. Cependant, ces techniques ont jusqu'à présent été mises en œuvre dans des domaines simples, sans obstacles, peuplés de points de repère. Le problème de la planification dans l'espace de croyance relève à son tour du cadre plus large des processus de décision de Markov partiellement observables (POMDP), et des travaux récents ont permis de trouver des moyens efficaces de résoudre les POMDP qui pourraient potentiellement être appliqués à l'exploration autonome de robots mobiles [30], [31].

Dans les sections qui suivent, nous décrivons notre cadre d'exploration EM proposé et son application à la cartographie sous-marine avec sonar, démontrant qu'il atteint des erreurs de localisation et de cartographie bien inférieures à celles des algorithmes d'exploration basés sur la frontière [10] et next-best-view [16], et que les erreurs de localisation et de cartographie obtenues sont comparables à celles de [28], tout en atteignant un taux d'exploration supérieur.

III. EXPLORATION EM

Nous abordons le problème de l'exploration autonome pour un robot mobile à détection de distance dans un environnement initialement inconnu. Notre robot effectue le SLAM et construit une carte de grille d'occupation au fur et à mesure de son exploration. Nous supposons un espace limité

espace de travail $2D \ V \subset \mathbb{R}^2$ où toutes les cellules discrétisées m sont initialisées comme inconnues ($m_i = 1$) = 0,5. Une frontière est définie comme la limite où l'espace libre rencontre l'espace non cartographié. L'exploration est considérée comme terminée si aucune frontière ne peut être détectée. Cependant, des poses très incertaines sont susceptibles de produire des cartes de grille d'occupation complètes mais inexactes, limitant l'utilité des informations obtenues en explorant l'espace inconnu. En supposant que l'environnement contient des

repères $L = \{l_k \in \mathbb{R}^2\}$, en plus de découvrir davantage de repères, minimiser l'erreur d'estimation est tout aussi crucial.

A. Localisation et Cartographie Simultanées

Nous utilisons une approche basée sur le lissage plutôt qu'une approche basée sur le filtrage, en adoptant le lissage et la cartographie incrémentaux [32] pour estimer à plusieurs reprises toute la trajectoire du robot. Cela nous offre la flexibilité d'adopter soit le SLAM basé sur les repères, soit le SLAM de pose, de manière évolutive sur des missions de longue durée. Il est important de noter que cela permet également d'apporter des corrections tout au long de la mission à la fois à l'historique des poses estimées du robot et à la carte de l'environnement résultant de cet historique de poses.

Soit le modèle de mouvement d'un robot mobile défini comme

$$x_i = f_i(x_{i-1}, u_i) + w_i, \quad w_i \sim N(0, Q_i), \quad (1)$$

où $x_i = [x_i, y_i, \theta_i] \in SE(2)$ désigne la pose du véhicule à l'instant i , $u_i \in \mathbb{R}^n$ désigne l'entrée de commande du véhicule, et $w_i \sim N(0, Q_i)$ est un bruit de processus gaussien additif à moyenne nulle avec une matrice de covariance Q_i . Soit le modèle de mesure défini comme

$$z_{ij} = h_{ij}(x_i, l_j) + v_{ij}, \quad v_{ij} \sim N(0, R_{ij}), \quad (2)$$

où nous obtenons une mesure entre le repère de repère l_k et la pose x_i , corrompée par un bruit de capteur gaussien additif à moyenne nulle v_{ij} avec une matrice de covariance R_{ij} . Nous supposons l'association de données

entre x_i, l_j est connu. Il est à noter que ce qui précède les définitions peuvent être étendues en 3D.

Étant donné les mesures $Z = \{z_k\}$, nous cherchons à obtenir la meilleure estimation de l'ensemble de la trajectoire $X = \{x_i\}$ et des repères observés $L = \{l_j\}$,

$$\begin{aligned} X^*, L^* | Z &= \underset{X, L}{\operatorname{argmax}} P(X, L, Z) \\ &= \underset{X, L}{\operatorname{argmax}} P(Z | X, L) P(X), \end{aligned} \quad (3)$$

où P est la vraisemblance des mesures ou des commandes entrées données par poses de véhicule et positions de repères. L'estimation du maximum a posteriori (MAP) peut être obtenue en maximisant la probabilité jointe, ce qui conduit ensuite à un problème de moindres carrés non linéaire. En construisant une représentation graphique et en linéarisant les fonctions non linéaires, les distributions marginales et les distributions marginales communes, qui sont toutes deux gaussiennes, peuvent être extraites à l'aide d'algorithmes d'inférence basés sur des modèles graphiques [32].




Fig. 1 : Une illustration de la propagation de croyance des actions candidates et des repères virtuels dans l'exploration EM.

B. EM-Exploration

Dans la formulation du problème SLAM comme un réseau de croyances [33], la solution est obtenue en maximisant la distribution de probabilité conjointe comme dans l'Équation (3). Pendant l'exploration, nous sommes confrontés à des repères inconnus qui n'ont pas encore été observés. Par conséquent, nous introduisons le concept de virtuel

repères V en tant que variables latentes, qui décrivent des potentiels positions de repères qui seraient observées en suivant le chemin prévu. Ensuite, l'objectif est de maximiser le modèle marginal suivant,

$$\begin{aligned} X^* &= \underset{X}{\operatorname{argmax}} \log P(X, Z) \\ &= \underset{X}{\operatorname{argmax}} \log \sum_V P(X, Z, V). \end{aligned} \quad (4)$$

L'équation ci-dessus implique des variables non observées, qui peuvent être abordées de manière intuitive en utilisant un algorithme d'espérance-maximisation (EM) comme suit,

$$\text{Étape E : } q(V) = p(V | X_{\text{old}}, Z) \quad (5)$$

$$\text{Étape M : } X_{\text{new}} = \underset{X}{\operatorname{argmax}} E_q(V) [\log P(X, V, Z)]. \quad (6)$$

À l'étape E, les points de repère virtuels latents V sont calculés en fonction de l'estimation actuelle de la trajectoire X_{old} et de l'historique des mesures Z . À l'étape M, une nouvelle trajectoire X_{new} est sélectionnée de sorte que la valeur attendue de la probabilité conjointe, étant donné les distributions des points de repère virtuels, soit maximisée. L'algorithme itératif alterne entre l'étape E et l'étape M, mais chaque itération est réalisée par l'exécution d'actions de contrôle et la collecte de mesures.

L'équation ci-dessus pose un défi pour une solution efficace en raison de la croissance exponentielle des configurations potentielles de points de repère virtuels par rapport au nombre de points de repère virtuels. Inspirée par les algorithmes EM de classification, une solution alternative consisterait à ajouter une étape de classification (étape C) avant l'étape M

pour fournir l'estimation de probabilité a posteriori maximale des distributions des repères virtuels,

$$\text{C-step: } V^* = \underset{V}{\operatorname{argmax}} p(V | X_{\text{old}}, Z) \quad (7)$$

$$\text{M-step: } X_{\text{new}} = \underset{X}{\operatorname{argmax}} \log P(X, V^*, Z). \quad (8)$$

Si nous supposons en outre que les mesures sont attribuées pour maximiser la vraisemblance

$$Z = \underset{Z}{\operatorname{argmax}} h(X, V),$$

où h est le modèle de mesure dans l'Équation (2), alors la distribution conjointe peut être exprimée comme une Gaussienne multivariable centrée sur les poses proposées et les positions des repères, et la covariance peut être approximée par l'inverse de la matrice d'information,

$$P(X, V, Z) \sim N \left(\begin{bmatrix} X \\ V \end{bmatrix}, \begin{bmatrix} \Sigma_{XX} & \Sigma_{XV} \\ \Sigma_{VX} & \Sigma_{VV} \end{bmatrix} \right), \quad (9)$$

où Σ_{XX} et Σ_{VV} sont les covariances marginales des poses et des points de repère respectivement. La solution de l'équation (8) équivaut à évaluer le logarithme du déterminant de la matrice de covariance,

$$\underset{X}{\operatorname{argmax}} \log P(X, V^*, Z) = \underset{X}{\operatorname{argmin}} \log \det(\Sigma). \quad (10)$$

Cela implique que la métrique de performance pour notre exploration proposée est cohérente avec le critère de D-optimalité dans le SLAM actif [34], sauf que les sujets considérés incluent des points de repère non observés.

C. Propagation de croyance sur les actions candidates

Puisque nous nous intéressons davantage à l'incertitude des points de repère virtuels et à la pose la plus récente x_{T+N} à l'étape Tavec un horizon de planification N , nous pouvons marginaliser les poses non pertinentes dans Σ_{XX} , ce qui donne Σ_{xT+N} . Typiquement, il existe des milliers de points de repère virtuels, ainsi l'approximation de Σ_{VV} est cruciale pour

applications en temps réel. Combiné à la simplification de la pose, nous pouvons obtenir que, pour une matrice de covariance définie positive,

$$\log \det(\Sigma) < \log \det(\Sigma_{xT+N}) + \sum_k \log \det(\Sigma_{vk}), \quad (11)$$

où Σ_{vk} est le bloc diagonal impliquant le k -ième point de repère virtuel dans Σ_{VV} . Cette approximation est raisonnable en considérant une surestimation de l'information en utilisant les points de repère virtuels introduits.

Nous discuterons du processus d'estimation de Σ_{xT+N} dans cette section et Σ_{vk} dans la section suivante. Ce processus est illustré dans la Figure 1. Au début, l'estimation de la pose existante et la covariance (en haut à gauche) peuvent être obtenues à partir du SLAM, et les actions candidates (en haut à droite) sont générées à partir d'une bibliothèque de trajectoires, qui sera discutée plus tard. Premièrement, étant donné un chemin candidat et des mesures prédites, la covariance des poses

le long de toute la trajectoire est mise à jour, c'est-à-dire, $\Sigma_{x1:T+N}$ (en bas à gauche). Deuxièmement, étant donnée l'incertitude prédite de la pose, nous approchons la covariance des points de repère virtuels indépendamment sans la matrice de covariance complète des poses (en bas à droite).

Le problème SLAM défini dans la section III-A peut être approximé par une linéarisation et résolu par itération à l'aide de la forme linéaire suivante :

$$\delta^* = \underset{\delta}{\operatorname{argmin}} \frac{1}{2} \|A\delta - b\|^2, \quad (12)$$

où A représente la matrice Jacobienne et le vecteur b représente les résidus de mesure. La mise à jour incrémentale δ dans l'équation ci-dessus est obtenue en résolvant le système linéaire,

$$A^T A \delta = A^T b. \quad (13)$$

Cela peut également être formulé comme $\Lambda \delta = \eta$ où $\Lambda = A^T A$ est appelée matrice d'information. En général, la matrice de covariance peut être obtenue en inversant la matrice d'information

$$\Sigma = \Lambda^{-1} = (A^T A)^{-1}. \quad (14)$$

Comme montré dans [35], la récupération des éléments diagonaux par blocs correspondant aux covariances de pose peut être réalisée efficacement. Par conséquent, nous nous intéressons au problème de la mise à jour de l'incertitude lors de l'arrivée de nouvelles mesures en supposant que

Σ_{xi} sont donnés. La figure 1 montre un scénario (de haut à droite vers le bas à gauche) dans lequel la croyance du robot sur sa trajectoire actuelle a été obtenue (noir) et des mises à jour (rouge) doivent être étudiées si de nouvelles mesures sont disponibles.

$$\begin{bmatrix} \Sigma_{x0} & \Sigma_{x0i} & \Sigma_{x0k} & \dots & \Sigma_{x0,k+n} \\ \dots & \ddots & \vdots & \dots & \vdots \\ \Sigma_{xi} & \dots & \vdots & \dots & \vdots \\ \dots & \dots & \vdots & \dots & \vdots \\ \Sigma_{xj} & \dots & \vdots & \dots & \vdots \\ \dots & \dots & \vdots & \dots & \vdots \\ \Sigma_{xk} & \dots & \vdots & \dots & \vdots \\ \dots & \dots & \vdots & \dots & \vdots \\ \Sigma_{xk+n} & \dots & \vdots & \dots & \vdots \end{bmatrix} \quad (15)$$

La récupération de la covariance s'effectue en trois étapes. Nous utilisons la Figure 1 et l'Équation (15) comme exemples illustratifs, où l'indice k désigne la pose la plus récente. Premièrement, nous calculons les entrées diagonales dans la matrice de covariance (en bleu). Deuxièmement, nous ignorons les mesures de fermeture de boucle et propageons la covariance en utilisant uniquement les mesures d'odométrie, qui peuvent provenir de l'odométrie des roues, de l'odométrie inertielle ou de l'appariement séquentiel des scans. Cette récupération de covariance en boucle ouverte est donnée par

$$\Sigma_{xi,k+t} = \Sigma_{xi,k+t-1} F_{k+t}, \quad (16)$$

où $F_{k+t} = \frac{\partial f_{k+t}}{\partial x_{k+t}}$ est la matrice jacobienne $\frac{\partial f_{k+t}}{\partial x_{k+t}}$ avec par rapport à la pose x_{k-1} . L'équation est appliquée de manière récursive et la valeur initiale $\Sigma_{xi,k}$ peut être calculée par

$$\Lambda \Sigma_{x^*,k} = I_k, \quad R \Sigma_{x^*,k} = R \Pi_k, \quad (17)$$

où $\Sigma_{x^*,k}$ représente la covariance croisée entre les poses passées les poses et la pose actuelle (colonne verte k) et I_k est une matrice colonne bloc clairsemée avec un bloc identité uniquement à la position correspondant à la pose k . La solution de l'Équation (17) est obtenue par décomposition de Cholesky à droite (le R est disponible immédiatement après la mise à jour incrémentale dans iSAM2 [32]), dont la complexité de calcul, pour une matrice R clairsemée avec N_{nz} éléments non nuls, est $O(N_{nz})$.

Enfin, nous utilisons la formule de Woodbury pour mettre à jour la matrice de covariance [36],

$$\Sigma = \Sigma + \Delta \Sigma, \quad \Delta \Sigma = -\Sigma A^T u (I + A \Sigma A^T u)^{-1} A \Sigma, \quad (18)$$

où Au est une matrice Jacobienne dont chaque ligne de bloc correspond à une mesure de fermeture de boucle. L'utilisation de la formule ci-dessus permet une mise à jour très efficace, car elle évite

l'inversion d'une grande matrice dense $(A^T A + A^T u A) - I$. En tout, notre processus de propagation de croyance nécessite la récupération des colonnes de blocs pour lesquelles la pose respective apparaît dans les mesures (par exemple, la colonne verte i de l'équation (15)), et une inversion de matrice relativement petite dont le nombre de lignes de blocs est égal au nombre de mesures de fermeture de boucle.

D. Propagation de croyance sur des points de repère virtuels

Supposons que le robot suivant un certain trajet puisse prendre des mesures à partir de points de repère dans l'environnement environnant. Soit $\{x_i \in SE(2)\}$ les poses du robot qui observent le même point de repère $l \in R^2$. Dans la dérivation suivante, nous ne distinguons pas entre le point de repère virtuel v et le point de repère réel

l (le processus prendra en compte les deux). La mesure z_i peut être obtenue à partir du modèle de capteur suivant

$$z_i = \tilde{z}_i + v_i = h_i(x_i, l) + v_i, \quad v_i \sim N(0, R_i). \quad (19)$$

Nous supposons en outre que le modèle du capteur est inversible, c'est-à-dire que nous sommes capables de prédire les positions des repères à partir des poses du robot et de leurs mesures correspondantes. Mathématiquement, la matrice jacobienne est de rang complet, $\text{rang}(\frac{\partial h_i}{\partial l}) = 2$. Un exemple d'un tel modèle est la mesure angle-distance, couramment produite par les télémètres laser. Dans nos expériences, nous étendons cette hypothèse aux sonars multifaisceaux. Nous négligeons leur largeur de faisceau horizontale en raison de leur haute résolution et de leurs faisceaux étroits, et nous négligeons la largeur de faisceau verticale car notre véhicule opère à une profondeur constante dans un environnement dont




Fig. 2 : Intersection de covariance à travers plusieurs poses de robot utilisée pour calculer une borne supérieure (ellipses rouges) sur la covariance réelle du repère (ellipses vertes). Les retours de portée-angle bruts de l'objet représenté par le repère l , appariés avec leurs plus proches voisins sur des poses successives du robot à l'aide de ICP, sont indiqués par des points bleus.

les structures fabriquées possèdent une section transversale fixe. Dans ce qui suit, nous utiliserons le modèle inverse du capteur par commodité,

$$l = h - l_i(x_i, \tilde{z}_i) = h - l_i(x_i, z_i - v_i), v_i \sim N(0, R_i). \quad (20)$$

Les matrices jacobiniennes du modèle inverse du capteur sont représentées comme $H_{h-1} \frac{\partial x}{\partial x} G = \frac{\partial h-1}{\partial x} \frac{\partial x}{\partial x} = \frac{\partial h-1}{\partial x} \frac{\partial x}{\partial x}$. Étant donné la covariance = matrices de poses $\begin{bmatrix} \Sigma_i & \Sigma_{ij} \\ \Sigma_{ij}^T & \Sigma_j \end{bmatrix}$, nous avons l'intention de fournir une estimation cohérente de la covariance d'un repère sans le calcul de $\{\Sigma_{ij} | i \neq j\}$, comme démontré en bas à droite de la Figure 1.

Supposons que nous obtenions deux mesures du même repère à deux poses distinctes x_i, x_j , entraînant une distribution conjointe

$$\begin{bmatrix} l_i \\ l_j \end{bmatrix} = \begin{bmatrix} h - l_i(x_i, z_i) \\ h - l_i(x_j, z_j) \end{bmatrix}. \quad (21)$$

$$\begin{aligned} \text{cov} \begin{pmatrix} l_i \\ l_j \end{pmatrix} &= \begin{bmatrix} \Sigma_i & \Sigma_{ij} \\ \Sigma_{ij}^T & \Sigma_j \end{bmatrix} \\ &= \begin{bmatrix} H_i & 0 \\ 0 & H_j \end{bmatrix} \begin{bmatrix} \Sigma_i & \Sigma_{ij} \\ \Sigma_{ij} & \Sigma_j \end{bmatrix} \begin{bmatrix} H_i & 0 \\ 0 & H_j \end{bmatrix}^T \\ &\quad + \begin{bmatrix} G_i & 0 \\ 0 & G_j \end{bmatrix} \begin{bmatrix} R_i & 0 \\ 0 & R_j \end{bmatrix} \begin{bmatrix} G_i & 0 \\ 0 & G_j \end{bmatrix}^T \end{aligned}$$

Soit $P_{i1} = H_i \Sigma_i H_i^T$, $P_{i2} = G_i R_i G_i^T$, $P_{ij} = H_i \Sigma_{ij} H_j^T$.

$$\text{cov} \begin{pmatrix} l_i \\ l_j \end{pmatrix} = \begin{bmatrix} \Sigma_i & \Sigma_{ij} \\ \Sigma_{ij}^T & \Sigma_j \end{bmatrix} = \begin{bmatrix} P_{i1} + P_{i2} & P_{ij} \\ P_{ij}^T & P_{j1} + P_{j2} \end{bmatrix}$$

Nous obtenons deux estimations de covariance indépendamment de deux poses et nous utiliserons l'intersection de covariance divisée (SCI) [37] pour calculer une borne supérieure sur la covariance du repère réel comme suit

$$\hat{\Sigma}^l, -1 = \frac{1}{\omega} (P_{i1} + P_{i2}) - 1 + \left(\frac{1}{1 - \omega} (P_{j1} + P_{j2}) - 1 \right), \omega \in [0, 1], \quad (22)$$

où ω peut être optimisé via

$$\omega^* = \underset{\omega \in (0,1)}{\text{argmin}} \det(\hat{\Sigma}^l). \quad (23)$$

Les lecteurs sont renvoyés à [37] pour l'analyse de SCI et la démonstration de la borne supérieure. Mais l'idée centrale est que si nous construisons un estimateur linéaire optimal et sans biais $\hat{l} = K_l i + K_j j (K_i + K_j =$

l), il peut alors être démontré que $\hat{\Sigma}^l \approx E[(\hat{l} - l)(\hat{l} - l)^T]$. Par conséquent nous sommes capables d'approcher davantage l'équation (11) par

$$\log \det(\Sigma) < \log \det(\Sigma x T + N) + \sum_k \log \det(\hat{\Sigma}^l v_k). \quad (24)$$

Nous démontrons le processus de l'intersection de covariance scindée incrémentale dans la Fig. 2. À chaque étape, une estimation de covariance d'un repère dérivée de la mesure collectée à une pose donnée est indiquée par une ellipse bleue foncée. Après la première étape, nous pouvons fusionner les observations de repères provenant de poses différentes via l'intersection de covariance, en utilisant l'Équation (22), comme le montrent les ellipses rouges. Il est évident que l'ellipse résultante de SCI (rouge) contient le vrai résultat obtenu par SLAM (vert).

E. Extensibilité à Pose SLAM

À partir de la dérivation ci-dessus, une borne supérieure de l'incertitude d'un repère réel ou virtuel peut être calculée à partir de plusieurs poses qui l'observent. Cependant, il convient d'explorer le sens de ce processus dans le contexte de Pose SLAM, où aucun repère n'est intégré dans notre optimisation. Pour simplifier le problème, nous supposons que les caractéristiques environnementales sont mesurées et que la transformation entre les poses avec observations chevauchantes est dérivée en utilisant le point le plus proche itératif (ICP) [38]. Nous visualisons un tel scénario à l'aide d'observations hypothétiques de portée-angle d'un objet (qui peut être représenté alternativement comme un repère) dans le graphique le plus à gauche de la Figure 2. Dans cet exemple, les observations sont distribuées normalement et centrées sur l'emplacement réel du repère. Nous supposons que cet ensemble de retours de portée-angle sera apparié à ceux des autres poses en utilisant ICP. Dans ICP, un point est associé à son plus proche voisin et la caractéristique appariée est donnée par

$$\tilde{l} = \underset{i}{\text{argmin}} \|l_i - l\|^2. \quad (25)$$

Il est ensuite trivial de montrer que

$$\Sigma^l \approx E[(\hat{l} - l)(\hat{l} - l)^T] \approx E[(\tilde{l} - l)(\tilde{l} - l)^T]. \quad (26)$$

La distribution de $\tilde{l}$ est visualisée à chaque étape dans la Figure 2.

Bien que nous visons à sélectionner des actions d'exploration qui réduisent les covariances des repères (virtuels) dans le SLAM basé sur les repères, nous minimisons essentiellement la proximité des mesures dans le SLAM de pose basé sur ICP. Comme l'erreur d'association est l'une des principales causes d'erreur ICP, des points cibles fortement regroupés contribuent grandement à la performance d'enregistrement.

F. Carte virtuelle

Comment pouvons-nous prédire des repères non observés sans connaissance préalable des caractéristiques d'un environnement ? Nous pouvons aborder cette question en faisant l'hypothèse conservatrice selon laquelle tout endroit qui n'a pas encore été cartographié possède un repère virtuel. De plus, la probabilité qu'un emplacement soit potentiellement occupé par un repère peut être capturée à l'aide d'une carte de grille d'occupation. Soit $P(m_i \in M)$ la probabilité d'occupation d'une cellule discrétisée, alors nous définissons une carte virtuelle V constituée de repères virtuels avec probabilité

$$P(v_i = 1) = \begin{cases} 1, & \text{si } P(m_i = 1) \geq 0,5 \\ 0, & \text{sinon.} \end{cases} \quad (27)$$

Dans sa définition, les repères existants ont été intégrés à la carte virtuelle, ce qui est essentiel car minimiser l'incertitude des repères observés est également souhaité.

Ce qui distingue une carte de grille d'occupation typique de notre carte virtuelle est le traitement de l'espace inconnu, ce qui détermine ensuite quelle métrique nous utilisons pour l'exploration. Dans la cartographie par grille d'occupation, afin de permettre l'exploration vers l'espace inconnu, l'entropie de Shannon est fréquemment exploitée pour optimiser un chemin qui fournit le gain d'information maximal [39]. Cependant, une autre métrique, telle qu'un critère d'optimisation défini sur la matrice de covariance, est nécessaire pour tenir compte de l'incertitude de cartographie et de localisation. En conséquence, les repères virtuels sont initialisés avec une grande incertitude, qui est réduite en prenant des mesures d'eux, ce qui aboutit à un gain d'information. La même métrique peut être encore optimisée en améliorant la localisation grâce aux fermetures de boucle, ce qui unit la mesure d'utilité utilisée à la fois pour l'exploration et la localisation. Un exemple de carte d'occupation utilisée pour maintenir des repères virtuels est fourni à la Figure 3, où elle est utilisée pour la propagation de croyances en soutien à la planification avec un robot sous-marin.

Bien que nous puissions utiliser la même carte de grille d'occupation issue de la planification de trajectoire, qui est généralement de haute résolution, pour construire la carte virtuelle à l'aide de l'équation (27), il a été démontré dans nos travaux antérieurs [2] qu'une carte virtuelle à basse résolution offre des performances d'exploration similaires mais nécessite moins de calculs. Par conséquent, dans nos expériences, nous réduisons la résolution de la carte de grille d'occupation de 0,2 m à $d = 2$ m, comme illustré à la Fig. 3.

La mise à jour de la carte virtuelle et l'estimation des covariances des points de repère virtuels sont décrites dans l'algorithme 1. La carte virtuelle est d'abord obtenue en réduisant la résolution de la carte de grille d'occupation, qui est construite à partir de la trajectoire du robot et des mesures collectées à chaque pose. Étant donné un chemin candidat $XT:T+N$, nous pouvons prédire les mesures potentielles de fermeture de boucle en fonction de l'algorithme SLAM spécifique. Par exemple, pour le SLAM basé sur les points de repère, une fermeture de boucle se produit lorsqu'un point de repère existant est observé à une pose future. Pour le SLAM de pose, nous prédisons une fermeture de boucle chaque fois que deux poses observent des obstacles avec un certain chevauchement, de sorte que l'appariement des scans soit possible. Nous notons que nous supposons des observations de maximum de vraisemblance lors de la prédiction des mesures futures. L'incertitude de la pose est mise à jour en fonction des actions et mesures candidates à l'aide de l'équation (18). Pour chaque point de repère virtuel, nous utilisons l'algorithme d'intersection de covariance pour estimer la covariance du point de repère virtuel comme décrit en section III-D.

Algorithme 1 Estimation de la covariance du repère virtuel

Exigences résolution de la carte virtuelle d , trajectoire X et mesures-
ments Z , chemin candidat $XT:T+N$ mesure future-
ments $ZT:T+N$

- 1 : $M \leftarrow$ Mise à jour de la carte d'occupation(X, Z)
- 2 : $V \leftarrow$ Sous-échantillonner(M, d) Eq. (27)
- 3 : $\Sigma \leftarrow$ Mise à jour de la covariance diagonale($X, Z, XT:T+N, ZT:T+N$) Eq. (16) - (18)
- 4 : pour $vk \in \{vi \in V \mid P(vi = 1) = 1\}$ faire
- 5 : $\Sigma vk \leftarrow$ CovarianceIntersect($\Sigma, XT:T+N, vk$) Eq. (19) - (23)
- 6 : fin pour

G. Planification de mouvement

Pour réaliser l'étape M de notre algorithme introduit à l'Équation (8), compte tenu de la distribution des repères virtuels, des candidats de chemin doivent être générés et évalués en utilisant la fonction utilité sélectionnée. Si nous devons considérer des chemins globaux qui seront suivis sur une longue période, nous devons tenir compte de deux types d'actions, l'exploration et les visites de lieux déjà parcourus [20].

Actions d'exploration ont normalement des destinations près de la frontière emplacements où les cellules cartographiées rencontrent des cellules inconnues, et pour réduire l'incertitude de localisation, les actions de révisite de lieux ramènent le robot à des emplacements qu'il a visités, ou où il peut observer un obstacle déjà observé. La prévalence de ces emplacements exige que nous examinions un grand nombre de cellules de grille libres afin d'obtenir une solution quasi-optimal.

Par conséquent, nous définissons deux ensembles de configurations d'objectif dans notre espace d'action. Un ensemble de configurations d'objectif de frontière G_{frontier} est utilisé pour l'exploration, et un ensemble de configurations d'objectif de révisite de lieu $G_{\text{revisitation}}$ est utilisé pour corriger l'erreur de localisation du robot. L'algorithme 2 est conçu pour générer les frontières, qui sont échantillonnées uniformément sur la limite entre les régions inconnues et explorées de l'espace de travail. Dans l'algorithme 3, l'ensemble de configurations d'objectif de révisite de lieu est généré en choisissant les candidats qui peuvent observer le plus grand

nombre de cellules occupées. La taille de $G_{\text{revisitation}}$ est corrélée au nombre de cellules occupées dans la carte actuelle.

Plus précisément, les cellules occupées sont divisées en k groupes en utilisant l'algorithme des k -moyennes, et les objectifs de révisite sont générés le long de la frontière d'un cercle placé au centre de chaque groupe, dont le rayon dépend de la portée du capteur. Pour chaque ensemble de configurations d'objectif, nous échantillonnons parmi les candidats disponibles afin de maximiser la distance au plus proche obstacle, ce qui est

réalisé à l'aide de la carte de dégagement C . Cette carte contient, dans chaque cellule inoccupée, la distance au plus proche obstacle.

Pour soutenir la planification de mouvement vers les ensembles de configurations d'objectif ci-dessus, une feuille de route finement discrétisée est générée au début d'une mission d'exploration (les limites de la région à explorer sont connues, et les arêtes de la feuille de route sont supprimées au fur et à mesure que des obstacles sont découverts), et les configurations d'objectif sont assignées à leurs voisins les plus proches dans la feuille de route. L'algorithme de recherche A^* [40] est adopté pour résoudre les plus courts chemins à source unique vers toutes les configurations d'objectif depuis la pose actuelle du robot, et nous sélectionnons le meilleur chemin parmi eux à l'aide d'une fonction d'utilité qui associe un chemin candidat à une valeur scalaire. Dans l'équation (11),

Algorithme 2 Configurations d'objectifs de frontière

Exiger: Cellules de frontière F , carte de dégagement c , nombre de peut-objectifs candidats N_f , distance minimale de séparation d

```

1:  $G_{\text{frontier}} \leftarrow \emptyset$ 
2: pendant que  $|G_{\text{frontier}}| < N_f$  faites
3:    $f^* \leftarrow \text{argmax}_{fi} c(fi)$ 
4:    $G_{\text{frontier}} \leftarrow G_{\text{frontier}} \cup \{f^*\}$ 
5:    $F \leftarrow F \setminus \{fi \mid |fi - f^*| \leq d\}$ 
6: fin de boucle
7: renvoyer les objectifs d'exploration candidats  $G_{\text{frontier}}$ 
```

Algorithme 3 Configurations d'objectifs de revisite de place

Exiger: Cellules occupées O , carte de dégagement c , nombre de peut-objectifs candidats N_r , rayon de revisite r , distance de séparation minimale d

```

1:  $G_{\text{revisitation}} \leftarrow \emptyset$ 
2:  $M = \{m_1, \dots, m_k\} \leftarrow \text{ComputeKMeans}(O, k)$ 
3: tandis que  $|G_{\text{revisitation}}| < N_r$  do
4:    $m^* = (x^*, y^*) \leftarrow \text{argmax}_{mi} |O_i|$ 
5:    $R^* \leftarrow \{(x^* + r \cos(\theta), y^* + r \sin(\theta)) \mid \theta \in [0, 2\pi)\}$ 
6:    $r^* \leftarrow \text{argmax}_{ri} R^* c(ri)$ 
7:    $d^* \leftarrow \min_{g_i \in G_{\text{revisitation}}} |r^* - g_i|$ 
8:   si  $d^* \geq d$  alors
9:      $G_{\text{revisitation}} \leftarrow G_{\text{revisitation}} \cup \{r^*\}$ 
10:  fin si
11:   $M \leftarrow M \setminus \{m^*\}$ 
12: fin tant que
13: retourner les objectifs de revisite candidats  $G_{\text{revisitation}}$ 
```

le déterminant logarithmique de la matrice de covariance est dérivé de l'étape M comme notre métrique d'incertitude. Étant donné que la covariance estimée doit être fusionnée avec une covariance initiale élevée, le déterminant logarithmique, ou le critère de D-optimalité, est garanti d'être non décroissant monotone au cours du processus d'exploration, ce qui est cohérent avec la conclusion dans [41]. En plus des critères d'incertitude, il est utile d'intégrer une term de coût à l'aller pour établir un compromis entre coût de déplacement et réduction de l'incertitude [20]. Ainsi, notre utilité est finalisée comme,

$$UEM(XT:T+N) = -\log \det(\tilde{\Sigma}X_{T:N}) - \sum_k \log \det(\tilde{\Sigma}v_k) - \alpha d(XT:T+N), \quad (28)$$

Où α est un poids sur la distance de parcours $d(XT:T+N)$. Dans nos expériences, nous adoptons une fonction de poids qui décroît linéairement par rapport à la distance parcourue, dont les paramètres sont déterminés expérimentalement et appliqués de manière cohérente dans nos comparaisons d'algorithmes ci-dessous. Le chemin sélectionné est exécuté immédiatement, mais pour tenir compte des écarts par rapport à la trajectoire nominale pendant l'exécution et des prédictions inexactes après la prise de nouvelles mesures (qui peuvent révéler de nouveaux obstacles), le chemin est abandonné lorsqu'il est bloqué par des obstacles, ou que le robot a parcouru une distance désignée. Le processus de planification d'exploration est répété jusqu'à ce qu'aucune nouvelle frontière ne soit détectée.

Comme nous pouvons le voir à partir de l'équation (28), l'utilité de la réduction de l'incertitude peut être annulée par le coût de l'action, et avec des paramètres mal sélectionnés, un robot peut rester bloqué à son emplacement actuel

emplacement. Par exemple, si l'antériorité des points de repère virtuels est petite, mais que le taux de dérive odométrique et l'incertitude du capteur de portée sont élevés, il est inutile d'agir pour explorer, car l'incertitude des points de repère virtuels ne sera pas réduite. Par conséquent, dans nos expériences, l'antériorité du point de repère virtuel est choisie pour être plus grande que l'incertitude maximale résultant d'une observation du capteur de portée à la fin d'une trajectoire longue de dead-reckoning. Cela garantit que notre robot explorera pleinement son environnement.

H. Analyse de la complexité algorithmique

Nous analysons brièvement la complexité computationnelle de l'algorithme d'exploration EM proposé. À chaque étape, nous générons

$N_f + N_r$ configurations d'objectifs au total et planifier les collisions-trajectoires libres vers chacun d'eux. Comme dans les algorithmes 2 et 3, les configurations d'objectifs peuvent être générées en $O(N_f N_{\text{cell}})$ et $O(N_r N_{\text{cell}})$ respectivement, où N_{cell} est le nombre de grilles cellules dans la carte de grille d'occupation. Toutes les covariances de pose sont estimées en utilisant les mesures prévues sur les trajectoires candidates,

chacun d'entre eux a une borne générale de $O(N^3 \text{ variables})$, où $N_{\text{variables}}$ est le nombre de variables dans le problème SLAM (c.-à-d., poses et repères). Cependant, grâce à une mise à jour incrémentielle de la covariance dans la Sec. III-C, nous sommes capables d'obtenir un calcul plus efficace en considérant qu'il y a peu de fermetures de boucle futures. Enfin, la covariance des repères virtuels est estimée, ce qui formule la fonction d'utilité. Comme la covariance des repères virtuels est calculée en fusionnant plusieurs sources,

il a une complexité $O(N_{\text{occupées}} N_{\text{poses}})$, où $N_{\text{occupées}}$ est le nombre de cellules occupées dans la carte virtuelle et N_{poses} est le nombre maximum de poses pouvant observer le même repère. Le calcul est grandement allégré... par le fait que nous utilisons une carte virtuelle à résolution faible et le nombre de cellules occupées diminue à mesure que nous explorons.

IV. SLAM SOTTOMARIN

Dans cette section, nous décrivons un plan, trois degrés de liberté (position x, y et cap θ) cadre SLAM qui nous permet de mettre en œuvre de manière robuste notre procédure d'exploration EM sur un robot sous-marin équipé d'un sonar dans un environnement portuaire encombré. Dans ce contexte, les observations des capteurs sont suffisamment denses pour qu'une approche SLAM de pose soit adoptée, utilisée en conjonction avec une cartographie d'occupation pour soutenir la planification de mouvement. Comme décrit dans les sections III-E et III-F, des points de repère virtuels sont également maintenus tout au long de l'espace de travail et utilisés pour évaluer la fonction utilité d'exploration EM. La propagation des croyances sur les points de repère virtuels dans ce cadre est illustrée à la Figure 3.

Le cadre SLAM sous-marin est construit sur un graphe de poses basé sur des images clés. Une image clé est ajoutée au graphe lorsque le robot se déplace de plus de 4 m ou tourne de plus de 30° ,

ce qui, comme montré à la Fig. 4, se produit typiquement à environ 0,2 Hz.

Compte tenu que notre ROV se déplace lentement et que son sonar a un champ de vision large, ce taux de mise à jour des images clés est suffisant pour soutenir nos expériences. L'interface principale, utilisée dans nos expériences sous-marines en temps réel, effectue l'appariement de balayage sur des caractéristiques extraites des images sonar dans les images clés. L'appariement de balayage repose sur une estimation initiale de pose à partir du calcul aujourd'hui, qui combine trois sources de mesures : Doppler




Fig. 3 : Planification sur des cartes virtuelles, avec plusieurs trajectoires candidates affichées. Des repères virtuels sont maintenus dans les cellules d'une carte d'occupation à faible résolution (les cartes d'occupation à résolution plus élevée utilisées pour la planification de mouvement et l'évitement des collisions sont montrées tout au long de la Section V). Les covariances d'erreur de toutes les cellules occupées et inconnues sont affichées sous forme d'ellipses dessinées à l'intérieur de chaque cellule de carte respective, ainsi que les contraintes de fermeture de boucle anticipées. Les cartes affichées ont été produites à partir de données sonar réelles de l'environnement illustré à la Fig. 15.




Fig. 4 : Diagramme du cadre SLAM sous-marin. L'interface avant et l'arrière-plan sont appliqués dans les expériences réelles de robot sous-marin, tandis que nos résultats basés sur la simulation n'utilisent que le backend SLAM.

journal de vitesse (DVL), unité de mesure inertielle (IMU) et capteur de pression (profondeur) à 5 Hz. Dans l'arrière-plan, les contraintes de l'avant-plan sont intégrées dans un graphe de facteurs ne comportant que les poses. L'optimisation du graphe de poses (utilisant iSAM2 [32]) fournit une estimation d'état à faible fréquence, qui est fusionnée avec le repérage sur pied pour produire une estimation à haute fréquence. Étant donné la trajectoire estimée et les points-features issus des images-clés, le module de cartographie génère une carte d'occupation utilisée pour soutenir la planification de mouvement. Le drift du repérage sur pied est corrigé grâce aux contraintes fournies par la détection d'ouverture de boucle, qui sert à faire correspondre l'image-clé actuelle avec l'historique des images-clés passées.

A. Extraction de caractéristiques

Le sonar d'imagerie en 2D émet des ondes sonores, et l'écho reçu par le sonar porte les caractéristiques de l'imagerie




Fig. 5 : Détection de caractéristiques SOCA-CFAR. Une image sonar brute d'un Oculus M750d avec 512 faisceaux est affichée en bas à gauche. Le seuil adaptatif correspondant au faisceau sonar marqué d'une ligne rouge est représenté par la ligne de tracé rouge en haut. Les cellules dont l'intensité est supérieure au seuil sont traitées comme des cibles, affichées en orange au centre-bas et transformées en coordonnées cartésiennes en bas à droite.

zone, qui est représentée par $\{(r_i, b_j), 0 \leq i \leq N_r, 0 \leq j \leq N_b\}$ en coordonnées polaires. Nous supposons que les mesures associées à chaque faisceau sont indépendantes et que chaque faisceau est traité séparément. Étant donné un faisceau de mesure d'intensité

$z_j = \{I_{ij} = I(r_i, b_j), 0 \leq i \leq N_r\}$, nous nous intéressons à l'identification des cas d'intervalle représentant des impulsions sonores renvoyées par des structures sous-marines.

Afin d'extraire des caractéristiques de manière fiable dans tous les types d'environnements avec des niveaux de bruit variés, nous utilisons un détecteur à Seuil Constant de Fausses Alarmes (CFAR), initialement conçu pour

radar, pour sonar d'imagerie 2D. Le CFAR utilise un seuil simple pour déterminer si un pixel dans une image donnée est un contact ou non, ce qui est obtenu en calculant une estimation du bruit pour la zone autour de la cellule testée (CUT) via une moyenne cellulaire. Une CUT est comparée aux statistiques de test en utilisant les cellules dans une

fenêtre glissante excluant la CUT. Soit $\tilde{T}_{ij}$ les statistiques dérivées de la fenêtre glissante (par exemple, l'intensité moyenne dans la fenêtre), et soit T_{ij} les statistiques de test.

Divers détecteurs CFAR ont été proposés, et d'après nos expériences avec le sonar d'imagerie, nous avons constaté que le CFAR à moyenne cellulaire du plus petit (SOCA-CFAR) [42] offre un compromis supérieur entre précision et coût computationnel. Dans la description de notre approche ci-dessous, nous adoptons la notation de [43].

Supposons que les cellules autour de la CUT sont

$\{l_i - N_j, \dots, l_i - 1_j, l_i + 1_j, \dots, l_i + N_j\}$. Les intensités moyennes calculées à partir du bord d'attaque et du bord de fuite de la fenêtre glissante sont données, respectivement, par

$$\tilde{T}_{ij,<} = \frac{1}{N} \sum_{n=1}^N l_{i-n,j}, \quad \tilde{T}_{ij,>} = \frac{1}{N} \sum_{n=1}^N l_{i+n,j}. \quad (29)$$

Les statistiques de test pour SOCA-CFAR sont alors données par

$$T_{ij} = \tau \min(\tilde{T}_{ij,<}, \tilde{T}_{ij,>}), \quad (30)$$

où τ , pour un taux de fausse alarme spécifié, peut être calculé comme suit [42],

$$P_{fa} = \alpha + \frac{\tau}{N-1} \sum_{n=0}^{N-1} \binom{N-1+n}{n} (2 + \frac{\tau}{N-1})^{n-1}. \quad (31)$$

Les caractéristiques détectées par SOCA-CFAR $\{(r_{ni}, b_{nj}) | 0 \leq n \leq N\}$ peuvent être transformées en coordonnées cartésiennes, formant un nuage de points 2D comme $\{p_n = (x_n, y_n) \in \mathbb{R}^2 | 0 \leq n \leq N\}$, où

$$x_n = r_{ni} \cos(b_{nj}), \quad y_n = r_{ni} \sin(b_{nj}). \quad (32)$$

Un exemple de SOCA-CFAR appliqué à un balayage sonar d'imagerie de structures dans une marina est présenté à la Figure 5. La Figure 5 (a) visualise le seuil de décision adaptatif $\tilde{T}_{ij}$ pour le faisceau sonar mis en évidence, et la Fig. 5 (b) visualise les points caractéristiques extraits en coordonnées polaires et cartésiennes.

B. Appariement de caractéristiques

Dans ce travail, nous supposons que notre robot fonctionne à une profondeur fixe et que le sonar prend des mesures uniquement à partir d'objets situés dans le même plan. Soient x_t et x_s une pose cible et une pose source

respectivement, et soient P_t et P_s les points cible et les points source mesurés à ces poses. Plus précisément, la transformation relative entre deux poses $x_t, x_s \in \text{SE}(2)$ combinant rotation $R_{ts} \in \text{SO}(2)$ et translation relative à récupérer $t_{ts} \in \mathbb{R}^2$, peut utiliser les techniques de correspondance de balayage.

L'algorithme le plus utilisé est le point le plus proche itératif (ICP) [38], qui minimise la fonction de coût suivante

$$J(x_t) = \sum_{p_t \in P_t, p_s \in P_s} \|t_{ts} p_s - p_t\|^2 \quad (33)$$

$$= \sum_{p_t \in P_t, p_s \in P_s} \|R_{ts} p_s + t_{ts} - p_t\|^2, \quad (34)$$




Fig. 6 : Illustration de notre méthode proposée d'appariement de balayage sonar appliquée à des images clés non séquentielles pour détecter une fermeture de boucle. Les points colorés (source) représentent les caractéristiques extraites de l'image sonar actuelle et les points noirs (cible) représentent les caractéristiques accumulées. De gauche à droite : transformation initiale à partir de l'odométrie ; résultat ICP basé sur la supposition initiale ; résultat d'initialisation globale de notre modèle de détection proposé ; résultat ICP affiné basé sur l'initialisation globale de la troisième colonne.

où $T_p = R_p + t$ représente la transformation de $p \in \mathbb{R}^2$ due au mouvement du robot $x \in \text{SE}(2)$. La correspondance entre p_t et p_s dans la fonction de coût ci-dessus est établie par recherche du plus proche voisin. Cependant, il est bien connu que l'ICP souffre du problème des minima locaux en raison de la non-convexité, et le résultat final dépend fortement de la qualité de la transformation initiale. Généralement, la supposition initiale est estimée par navigation à l'estime - par exemple, à partir de l'IMU ou de l'odométrie des roues. L'appariement de balayage utilisant l'ICP est encore plus affecté dans les environnements sous-marins, en raison de la quantité relativement faible de points dans un balayage sonar typique et des niveaux de bruit plus élevés.

Nous proposons d'atténuer le problème des minima locaux dans l'ICP en effectuant une initialisation globale au préalable. Ensuite, l'ICP est utilisé pour affiner localement l'estimation. Soit $\tilde{s}$ la pose source initialisée globalement.

$$\tilde{s} = \underset{x_s}{\operatorname{argmax}} \sum_{p_s \in P_s} I(d(p_s) \leq \epsilon), \quad (35)$$

où $I = 1$ lorsque la condition est vraie, et $I = 0$ sinon. d est défini comme la distance au point cible le plus proche,

$$d(p_s) = \min_{p_t \in P_t} \|R_{ts} p_s + t_{ts} - p_t\|. \quad (36)$$

La Figure 6 montre des résultats expérimentaux représentatifs de l'appariement de caractéristiques appliqué à une fermeture de boucle où une dérive importante par rapport à la mesure d'odométrie initiale est observée. Comme on peut le voir, la solution proposée en plusieurs étapes donne de bons résultats.

C. Construction du graphe de facteurs

Dans cette section, nous discutons de la construction des nœuds de facteur dans le graphe des facteurs SLAM. Comme illustré à la Figure 7, il existe deux types de nœuds de facteur, calculés à partir de l'appariement de balayage séquentiel et d'un appariement de balayage non séquentiel (désignés respectivement par les nœuds verts et orange). Les facteurs séquentiels représentent la transformation par rapport à la pose précédente ; l'erreur s'accumule inévitablement le long de la chaîne de poses. En revanche, les facteurs non séquentiels, également appelés fermeture de boucle




Fig. 7 : Composants clés du système SLAM. La variable de pose à chaque image-clé est notée par un carré noir. Le graphe factoriel central est composé de variables de pose aux images-clés (carrés noirs) et de deux types de facteurs : facteurs d'appariement de balayage séquentiels (cercles verts) et facteurs de fermeture de boucle (cercles orange). Chaque image-clé est associée à des points de caractéristiques détectés dans l'image sonar. Les points détectés à chaque image-clé contribuent indépendamment à la carte d'occupation.

contraintes, connectent deux poses qui sont séparées dans le temps et peuvent ainsi corriger l'écart accumulé entre les poses séquentielles. Le graphe de facteurs est donné par

$$f(\Theta) = f_0(\Theta_0) \prod_i f_{0i}(\Theta_i) \prod_j f_{jSM}(\Theta_j) \prod_q f_{qSSM}(\Theta_q).$$

Les facteurs séquentiels entre deux poses consécutives x_{k-1} et x_k peuvent être calculés par appariement de scans, en utilisant les nuages de points collectés à ces deux poses. Pour augmenter la robustesse de l'appariement, nous incorporons des caractéristiques extraites des $N_{SSM} > 1$ images précédentes, en supposant que la dérive est négligeable sur une courte période. L'appariement non séquentiel suit la même procédure que l'appariement séquentiel, sauf que les points cibles correspondent à des scans mesurés à des moments antérieurs. Nous limitons la fenêtre de recherche des poses cibles à celles situées en dehors d'un intervalle de temps minimum désigné à partir de la pose actuelle

pose, en imposant la condition $k - t_n > N_{sep}$, où t_n est le image clé la plus récente parmi les candidats de pose cible. Toutes les images clés éligibles subissent une initialisation ICP globale (Eq. (35)), et une fois cette étape terminée, les images clés qui ne se chevauchent pas avec l'ensemble des points sources sont écartées. L'image clé offrant le chevauchement maximal avec l'ensemble des points sources est adoptée comme pose cible.

Bien que quelques méthodes de vérification soient discutées, éviter la détection erronée de fermeture de boucle mérite des contre-mesures supplémentaires. Nous observons que les contraintes de fermeture de boucle correctes doivent être cohérentes (définies ci-dessous) avec l'estimation de la pose actuelle et potentiellement avec les futures contraintes de fermeture de boucle. Par conséquent, en supposant que les valeurs aberrantes sont rares, un ensemble de mesures cohérentes est probablement correct.

Nous adoptons la maximisation de l'ensemble des mesures cohérentes par paires (PCM) [45] pour rejeter les valeurs aberrantes. Soit $\hat{x}_{ij}$ et $\hat{x}_{ik}$ une paire de mesures de fermeture de boucle et nous supposons





Fig. 8: Quatre paires de fermetures de boucle détectées comme contraintes entre 2 images-clés. Celle erronée (rouge) est exclue dans le clique maximal.



(a) Image sonar brute (couleur dans-décalage pixel intensity) (b) Sous-map en coordonnée polaire (probabilité d'occupation affichée)

Fig. 9: Modèle inverse du capteur et la sous-map à partir d'une image sonar. La portée du capteur augmente à partir du haut de l'image vers le bas.

$l < k$. Une estimation des $\hat{x}_{ik}$ peut être obtenu en supposant poses et des mesures $\hat{x}_{jl}$ estimé comme suit

$$\hat{x}_k = x_{ij} \oplus \hat{x}_{jl} \oplus x_{lk}. \quad (37)$$

Les deux contraintes sont déterminées comme étant cohérentes par paire si la condition suivante est satisfaite,

$$\|\hat{x}_{ik} \ominus \hat{x}_k\|_{\Sigma} \leq \eta_{pcm}, \quad (38)$$

où $\|\cdot\|_{\Sigma}$ est la distance de Mahalanobis, η_{pcm} est une valeur prédéfinie le seuil et Σ peuvent être obtenus à partir de la covariance ICP $\hat{\Sigma}^{ik}$. Étant donné un ensemble de mesures, une vérification de cohérence mutuelle est effectuée. Un exemple avec quatre mesures est illustré à la Figure 8, où seulement trois des six paires possibles de mesures de fermeture de boucle sont cohérentes deux à deux. Le plus grand sous-ensemble de mesures cohérentes deux à deux, où chaque paire du sous-ensemble est cohérente, peut être identifié comme une clique maximale dans un graphe.

D. Cartographie d'occupation

Notre cadre de cartographie d'occupation est basé sur l'algorithme de cartographie par grille d'occupation [46]. La carte entière est discrétisée uniformément en cellules de grille indépendantes et la probabilité d'occupation de chaque cellule est mise à jour de manière récursive à l'aide d'un filtre de Bayes. Cependant, notre estimation d'état issue du SLAM présente une dérive importante, et lorsque la dérive est corrigée par des fermetures de boucle, il est souhaitable de corriger l'erreur de cartographie d'occupation en utilisant la trajectoire mise à jour. Par conséquent, nous utilisons un algorithme de cartographie d'occupation basé sur des sous-cartes [47], qui construit une carte locale ancrée à chaque image clé. Cette approche permet de recalculer efficacement la carte lorsqu'un segment de la trajectoire est modifié.

1) Fusion des sous-cartes : Supposons que nous puissions obtenir les poses des images clés dans un repère de référence à partir du SLAM noté $X = \{x_k\}_{k=1}^K$. Étant donné l'image sonar et les caractéristiques extraites, nous pouvons construire une sous-carte située dans un repère local noté $S_k = \{m_k\}$, où $m_k \in \mathbb{R}^2$ représente une cellule de grille 2D dans le




Fig. 10 : Exemples de simulation SLAM avec repères utilisant les algorithmes NF, NBV, Heuristic et EM dans l'environnement depicted dans la Fig. 12 (a). Chaque quadrant montre les résultats d'une trace d'exécution représentative. Dans le quadrant à gauche, la carte d'occupation avec l'historique de pose et les contraintes de mesure des repères est affichée. À droite, un graphique de la couverture de la carte, l'incertitude de pose, l'erreur de carte et l'erreur de pose sont affichés en fonction de la distance parcourue.




Fig. 11 : Moyennes des performances d'exploration dans l'environnement de repères de la Fig. 12 (a) pour 45 essais (cinq pour chaque position de départ du robot illustrée en Fig. 12), avec intervalles de confiance à 95 %. Les valeurs sur l'axe des abscisses indiquent la distance parcourue par le robot.

k -ième image clé. Soit $p(m_k | i = 1)$ la probabilité que la cellule soit occupée et $l_k(m_k | i = 1) = \log \frac{p(m_k | i = 1)}{1 - p(m_k | i = 1)}$ sa notation en log-odds. Nous utilisons l'exposant k pour désigner les cellules ou les valeurs log-odds dans la k -ième image clé. La carte entière est représentée comme la composition des sous-cartes $M = \{S_k\}_{k=1}^K$.

Dans cet article, une sous-carte ne consiste qu'en une seule image sonar, ainsi les valeurs d'occupation peuvent être calculées directement à partir du modèle inverse du capteur. Contrairement aux faisceaux laser, le sonar peut détecter des cibles cachées derrière le premier objet le long d'un faisceau en raison de sa large ouverture verticale. Ce phénomène est évident dans nos résultats expérimentaux, car il existe des quais flottants qui ne bloquent pas complètement les faisceaux sonar. De façon similaire au modèle inverse pour les faisceaux laser, où

cellules avant, autour et derrière un point de contact sont modélisées comme libre, occupée et inconnu, respectivement, nous traitons également les coups points derrière le premier comme occupés. En essence tous les cibles détectées sont supposées occupées, mais seule la zone devant la première cible est supposée être libre d'obstacles. Le modèle inverse du capteur est illustré à la Figure 9 ; une convolution gaussienne est utilisée pour lisser la probabilité d'occupation autour des points de contact.

Étant donné plusieurs poses de frames-clés et leurs correspondances

sous-cartes X^M , nous souhaitons produire une carte d'occupation $\{m_i\}$ dans le repère global. Les probabilités d'occupation de ses cellules intègrent les mesures de différentes poses, qui peuvent être mises à jour de façon incrémentale via le filtre de Bayes comme

$$l(m_i) = \sum_{S_k \in M} l_k(Tkgm_i), \quad (39)$$

où $Tkgm_i$ représente l'action de transformer les cellules de quadrillage global en un cadre local. Nous ignorons le prior dans la somme car par défaut nous supposons un prior non informatif pour la carte d'occupation $p(m_i = 1) = 0,5$. Par conséquent, les odds log d'occupation résultants sont simplement la somme des log-odds à travers les divers sous-cartes individuels.

2) Mise à jour d'une sous-map : Ajout de facteurs non séquentiels entraînant des changements fréquents dans l'historique de pose. Nous mettons à jour la contribution du k -ième image clé lorsqu'un changement, y compris la translation et la rotation, dépasse un seuil spécifié. Comme la règle de plafonnement [48] n'est pas utilisée lors de la fusion des sous-cartes, la mise à jour due au changement de pose peut être implémentée efficacement par

alg/distances	0	50	100	150	200	250	300	350	400
EM	0.10	0.34	0.30	0.32	0.33	0.31	0.31	0.29	0.28
NF	0.10	0.33	0.44	0.43	0.46	0.45	0.40	0.39	0.40
NBV	0.10	0.35	0.53	0.57	0.53	0.45	0.36	0.36	0.35
Rationnel	0.10	0.34	0.32	0.30	0.31	0.30	0.31	0.28	0.31

TABLEAU I : incertitude de pose dans l'environnement portuaire simulé.

alg/distances	0	50	100	150	200	250	300	350	400
EM	0.75	1.72	1.83	1.89	1.90	1.93	1.93	1.96	1.97
NF	0.75	1.79	1.94	1.97	2.06	2.07	2.08	2.07	2.08
NBV	0.75	1.73	1.90	1.99	2.07	2.05	2.05	2.05	2.05
Rationnel	0.75	1.72	1.84	1.88	1.91	1.94	1.95	1.96	1.98

TABLEAU II : erreur de pose dans l'environnement portuaire simulé.

alg/ couverture	50%	60%	70%	80%	90%
EM	13.79	39.53	80.92	157.15	303.92
NF	14.90	43.63	88.38	172.30	268.67
NBV	13.90	40.55	70.36	117.93	234.01
Rationnel	14.23	41.41	80.12	186.63	396.52

TABLEAU III : distance de déplacement pour atteindre les % désignés de couverture dans l'environnement portuaire simulé.

alg/distances	0	50	100	150	200	250	300	350	400
EM	0.56	0.90	0.95	0.97	1.00	1.03	1.05	1.06	1.05
NF	0.60	0.97	1.03	1.08	1.13	1.15	1.12	1.13	1.13
NBV	0.58	0.87	1.01	1.08	1.12	1.12	1.12	1.12	1.12
Heuristique	0.58	0.90	0.94	0.98	0.99	1.01	1.02	1.03	1.03

TABLEAU IV : Erreur de carte dans l'environnement marin simulé.




Fig. 12 : Environnements d'exploration simulés pour le SLAM de repères et de pose. La boîte de délimitation d'exploration est indiquée par un rectangle bleu, et l'exploration est initialisée à partir des triangles verts. Le robot ne peut se déplacer que dans la boîte et seules les observations de la zone à l'intérieur de la boîte de délimitation sont utilisées pour évaluer la couverture de la carte.

suppression des valeurs de probabilités log-odds précédentes et ajout des nouvelles,

$$l_{\square}(m_i) = l(m_i) - \underbrace{l_k(T_{kg} m_i)}_{\text{suppression de la mise à jour ancienne}} + \underbrace{l_k(T_{\square} kg m_i)}_{\text{ajouter une nouvelle mise à jour}}. \quad (40)$$

Dans l'équation ci-dessus, la sous-cartographie locale représentée par des valeurs de log-odds n'a pas besoin d'être recomputée.

En pratique, la sous-cartographie pour chaque image-clé stocke les indices de ses cellules de grille associées dans le cadre global. Lors de la mise à jour, nous soustrayons simplement les valeurs log-odds des anciens indices globaux et ajoutons les valeurs log-odds mises à jour aux nouveaux indices appropriés. Des exemples du cadre de cartographie d'occupation décrit ici sont montrés tout au long des résultats expérimentaux ci-dessous.

V. RÉSULTATS EXPÉRIMENTAUX

Ici nous présentons les résultats expérimentaux de (1) une simulation d'un robot sous-marin équipé d'un sonar explorant et cartographiant deux environnements plans, préalablement non cartographiés, et (2) l'exploration autonome réelle d'un environnement portuaire avec un robot sous-marin BlueROV2. L'un des environnements de simulation est peuplé de points de repère, permettant une solution qui utilise des nœuds de repère dans le graphique de facteur SLAM. L'autre environnement est peuplé de structures hétérogènes, auxquelles le SLAM de pose est appliqué à la place.

Les environnements de simulation ont été conçus pour émuler notre expérience réelle ultérieure et visent à évaluer nos algorithmes quantitativement sur un plus grand nombre d'essais. Le sonar simulé fonctionne à 5 Hz et a un champ de vision avec une portée $r = [0 \text{ m}, 30 \text{ m}]$ et une ouverture horizontale $\theta = [-65^\circ, 65^\circ]$. Comme nous supposons un environnement en 2D, l'ouverture verticale est ignorée dans la simulation. Un bruit gaussien à moyenne nulle est ajouté aux mesures de portée et d'angle : $\sigma_r = 0,2 \text{ m}$, $\sigma_\theta = 0,02 \text{ rad}$. Nous fournissons des mesures d'odométrie simulées à 5 Hz, qui peuvent être obtenues à partir des capteurs DVL et IMU dans nos expériences réelles. De plus, nous ajoutons du bruit gaussien à moyenne nulle à la transformation 2D : $\sigma_x = \sigma_y = 0,08 \text{ m}$, $\sigma_\theta = 0,003 \text{ rad}$.

Les deux cartes utilisées pour les expériences simulées sont montrées à la Figure 12. Dans la carte des repères (contenant une collection de repères générée aléatoirement et maintenue constante tout au long des essais), le robot est déployé à partir de neuf positions de départ différentes. Dans la carte SLAM de pose (dont les structures proviennent de nos résultats expérimentaux réels), le robot est déployé à partir de l'une des six positions de départ. Le processus d'exploration se termine lorsqu'il n'y a plus de fronts dans la carte qui peuvent être atteints de manière faisable par notre planificateur.




Fig. 13 : Exemples de simulation Pose SLAM utilisant les algorithmes NF, NBV, Heuristic et EM dans l'environnement de marina illustré à la Fig. 12 (b). Chaque quadrant montre les résultats d'une trace d'exécution représentative. Dans chaque quadrant à gauche, la carte d'occupation avec l'historique des poses et les contraintes de fermeture de boucle est montrée. À droite, un graphique de la couverture de la carte, l'incertitude de pose, l'erreur de carte et l'erreur de pose sont montrés en fonction de la distance de déplacement.




Fig. 14 : Moyennes des performances d'exploration dans l'environnement de marina simulé de la Fig. 12 (b) pour 60 essais (dix pour chaque position de départ du robot illustrée dans la Fig. 12), avec intervalles de confiance à 95 %. Les valeurs sur l'axe des abscisses indiquent la distance parcourue par le robot.

Nous considérons les métriques suivantes pour évaluer un algorithme d'exploration. L'incertitude de la pose mesure l'incertitude de la position actuelle du véhicule, calculée comme $\sqrt{\sum x_i^2}$. L'erreur de trajectoire représente l'erreur quadratique moyenne (RMSE) de la pose.

l'estimation sur toute la trajectoire $\sqrt{\frac{1}{N} \sum_{i=1}^N (\|x_i - x_{gt}\|_2)^2}$, où x_{gt} désigne la pose de référence. Le progrès de l'exploration est représenté par la couverture de la carte, c'est-à-dire le ratio de la zone cartographiée sur l'ensemble de l'espace de travail. Nous utilisons la RMSE du nuage de points reconstruit des repères comme indicateur de la carte.

erreur $\sqrt{\frac{1}{N} \sum_{j=1}^N (\|p_j - p_{gt}\|_2)^2}$, où le repère estimé est position p_j obtenu en utilisant le modèle inverse du capteur proposé estimée fournie, et p_{gt} désigne le repère du repère réel position. Il convient de noter que l'erreur de carte peut être appliquée à SLAM basé sur les repères ainsi qu'à SLAM d'attitude comme montré dans les expériences ci-dessous.

A. Comparaison des algorithmes

Dans les comparaisons suivantes, quatre algorithmes sont considérés, chacun utilisant différentes techniques pour sélectionner de façon répétée l'une des configurations cibles générées par notre planificateur de mouvement décrit en Sec. III-G. Tout d'abord, nous examinons l'exploration basée sur les frontières [10], qui explore en se déplaçant de façon répétée vers

en se déplaçant vers la frontière la plus proche configuration cible. Deuxièmement, nous examiner un cadre d'exploration next-best-view qui sélectionne la configuration cible anticipée pour atteindre le plus grand gain de formation par rapport à la carte d'occupation du robot, conformément à la technique proposée dans [16]. Troisièmement, nous examinons le cadre SLAM actif de [28]. Lorsqu'un l'incertitude de la pose du robot (conformément au critère de D-optimalité [34]) dépasse un seuil désigné, ce cadre sélectionne la configuration d'objectif de révisitation de place qui maximise une fonction d'utilité exprimant un compromis pondéré entre incertitude

réduction et gain d'information. À tout autre moment, l'approche revient à celle de [16], cherchant uniquement le gain d'information. Dans les résultats suivants, nous ferons référence à cette approche comme

heuristique, en raison de son utilisation d'un seuil ajusté sur l'incertitude de pose pour déterminer quand la revisite d'un lieu se produit. Ces trois algorithmes sont comparés à notre algorithme d'exploration EM proposé. Les algorithmes heuristique et EM ont été paramétrés pour obtenir la plus grande équivalence possible en erreur d'estimation de trajectoire (l'erreur quadratique moyenne de l'historique complet des poses, enregistrée à chaque instant pendant l'exploration), fournissant une base pour examiner d'autres caractéristiques de performance qui diffèrent.

B. Exploration simulée sur des points de repère

Dans l'environnement de points de repère illustré à la Figure 12a, nous comparé les algorithmes de frontière la plus proche (NF), next-best-view (NBV), heuristique et EM sur 45 essais simulés (cinq pour chaque position de départ du robot). Dans cet environnement, les points de repère sont supposés être infiniment petits et ne présentent pas de risque de collision. Nous fournissons des exemples représentatifs des quatre algorithmes d'exploration à la Figure 10. La performance moyenne des quatre algorithmes d'exploration est présentée à la Figure 11. La méthode NBV atteint une couverture supérieure de l'environnement, mais elle présente également la plus grande incertitude de pose, erreur de trajectoire et erreur de carte. L'approche NF atteint une couverture moins bonne que NBV, mais obtient une incertitude de pose et une erreur de carte/trajectoire plus faibles pendant l'exploration. L'approche heuristique couvre l'environnement le moins efficacement, tout en offrant la plus faible incertitude de pose et erreur de carte pendant le processus d'exploration. Notre algorithme EM proposé atteint une couverture de carte supérieure à l'approche heuristique, avec une incertitude de pose et une erreur de carte comparables mais légèrement supérieures.

C. Exploration simulée avec Pose SLAM dans un environnement portuaire

Comme il n'y a pas d'information de vérité terrain disponible dans nos expériences réelles, nous avons créé la carte simulée de la Fig. 12b à l'aide de données collectées manuellement dans l'environnement portuaire utilisé lors de ces expériences. Plus précisément, la carte simulée de la Fig. 12b est représentée par un nuage de points obtenu à partir du cadre SLAM décrit ci-dessus en Sec. IV. Lors de l'exploration simulée, les points caractéristiques qui tombent dans le champ de vision du capteur sont échantillonnés et un bruit gaussien est ajouté - ces observations de capteur sont utilisées pour remplir une carte d'occupation, comme décrit en Sec. IV-D. Dix essais de chaque algorithme ont été réalisés à chacun des six emplacements de départ différents (indiqués par des triangles verts à la Figure 12). Les erreurs de cartographie et de localisation sont rapportées par rapport à notre carte de nuage de points de vérité terrain dérivée expérimentalement. L'erreur de cartographie est calculée comme suit : pour chaque point caractéristique estimé, nous calculons sa distance au point de vérité terrain le plus proche.

La performance moyenne de chaque algorithme est présentée à la Figure 14, avec des valeurs numériques spécifiques de cette performance

comparaison donnée dans les Tableaux III et IV. Comme précédemment, la L'algorithme NBV réalise l'exploration la plus efficace, mais au prix d'une forte incertitude de pose, d'une erreur de carte et d'une erreur de trajectoire. L'incertitude de pose, l'erreur de trajectoire et l'erreur de carte




Fig. 15 : Le robot BlueROV2 instrumenté sur mesure utilisé dans nos expériences, et une illustration de la configuration de nos expériences à l'U.S. Merchant Marine Academy à King's Point, NY.

des algorithmes heuristique et EM sont similaires en valeur, et nettement inférieurs à ceux des algorithmes NF et NBV. Bien que les algorithmes heuristique et EM aient une incertitude de pose et une erreur de carte/trajectoire similaires, l'approche heuristique est moins performante que EM en termes de couverture de carte, ce qui est particulièrement évident dans le Tableau III, qui indique la distance totale parcourue pour atteindre divers pourcentages de couverture.

À la Figure 13, une trace d'exécution représentative de chaque algorithme est présentée. Un phénomène similaire, une interconnexion dense de contraintes de fermeture de boucle entre les poses, peut être observé dans la performance des algorithmes Heuristique et EM. En revanche, les algorithmes gloutons (NF et NBV) suivent des chemins similaires vers le coin supérieur droit au début, ce qui conduit à une incertitude de pose croissante. Bien que l'incertitude de pose soit finalement réduite, la précision de la carte est affectée comme le montrent la Figure 14 et le Tableau IV.

D. Exploration avec un robot sous-marin réel dans un environnement portuaire

Le matériel utilisé pour tester ce travail est un BlueROV2 modifié, illustré à la Fig. 15. Cette plateforme accueille un sonar imageur multi-faisceaux Oculus M750d, un DVL Rowe SeaPilot, une IMU VectorNav VN100 et un capteur de pression Bar30. Comme dans notre simulation, le champ de vision du sonar est

$r = [0\text{m}, 30\text{m}]$ et $\theta = [-65^\circ, 65^\circ]$, avec une 20° verticale ouverture. Bien que l'angle de tangage du sonar soit ajustable, dans les expériences suivantes, il est réglé à 0° . Le sonar fonctionne à 750MHz avec 512 faisceaux, une résolution de portée de 4mm et 1° de résolution angulaire. Le ROV est exploité à une vitesse fixe




Fig. 16 : Exemples du processus de planification de mouvement utilisé pour soutenir l'exploration. Les carrés violets sont des candidats de frontière, les flèches violettes sont des candidats de revisite de lieu. Les lignes bleues sont des trajectoires candidates et le graphe vert est utilisé pour la planification globale en conjonction avec A*.

profondeur de 1 m tout au long de nos expériences. Les données sont transmises via un câble à un ordinateur portable de surface et traitées en temps réel sur l'ordinateur portable. L'ordinateur portable de surface est équipé d'un processeur Intel i7-4710 quad-core, d'un GPU NVIDIA Quadro K1100M et de 8 Go de RAM. Tous les composants de la pile logicielle sont gérés par l'ordinateur de surface, y compris le traitement d'image, la solution SLAM, la propagation de croyance, la planification de mouvement et l'envoi des commandes au véhicule. La pile de navigation du Robot Operating System (ROS) est utilisée pour la planification et le contrôle des mouvements, avec un planificateur global personnalisé comme décrit en Sec. III-G, et le planificateur local timed elastic band [49]. L'implémentation GTSAM [50] de iSAM2 [32] est utilisée pour l'optimisation du graphe de poses dans notre back-end SLAM. Aucune intervention humaine n'a été nécessaire pendant les expériences, à part dérouler et rétracter le câble au besoin. Des exemples du processus de planification de mouvement lors de l'exploration d'un environnement inconnu par le ROV sont donnés à la Figure 16.

l'Académie de la marine marchande des États-Unis (USMMA). Un aperçu de la configuration de l'expérience est présenté à la Fig. 15. Avant de lancer le véhicule, il est manuellement dirigé vers une position de départ alignée avec les axes montrés sur la figure (avec le champ de vision du sonar centré sur l'axe rouge). À la Fig. 15, la carte estimée (représentée par un nuage de points coloré par le temps), la trajectoire estimée du robot et les mesures de fermeture de boucle sont visualisées, superposées à des images satellites. Nous notons que l'imagerie satellite est alignée manuellement avec ces résultats, servant uniquement d'indicateur qualitatif de l'écart entre la vérité terrain et la carte estimée. L'objectif est d'explorer et de cartographier les parties de l'environnement situées dans une boîte englobante de dimensions 130 m × 60 m. Trois essais ont été réalisés pour chacun des quatre algorithmes concurrents, et les résultats sont présentés aux Figs. 17 et 18. En raison du manque d'informations de vérité terrain et du nombre limité d'expériences répétées (en raison de la durée de chaque expérience et de la disponibilité limitée de l'installation), la performance d'exploration, évaluée

Des expériences en conditions réelles ont été menées dans une marina à




Fig. 17: Trois exécutions d'exploration de robot en monde réel utilisant les algorithmes NF, NBV et heuristique dans l'environnement représenté à la Fig. 15. Chaque exécution montre l'historique de pose du BlueROV et les contraintes de fermeture de boucle sur la carte d'occupation à gauche, avec la couverture et l'incertitude de pose affichées à droite, tracées par rapport à la distance parcourue.

par rapport à la couverture de la carte et à l'incertitude de pose tracées par rapport à la distance parcourue, est présenté pour mieux comprendre le fonctionnement des quatre algorithmes en compétition. Quatre étapes intermittentes et les résultats finaux de l'exploration sont tracés dans la Fig. 18, et pour économiser de l'espace, seul l'état final de l'exploration est tracé pour les algorithmes NF, NBV et heuristique dans la Fig. 17. En tant que ressource complémentaire, les douze essais peuvent être visionnés côte à côte dans leur intégralité dans notre pièce jointe vidéo.

À partir de la Fig. 17, il est évident que les algorithmes NF et NBV prennent des actions qui favorisent l'exploration, ce qui entraîne des trajectoires qui se dirigent rapidement vers le coin supérieur droit de la carte. En conséquence, les fermetures de boucle sont ajoutées plus tard que pour les algorithmes heuristique ou EM, et les fermetures de boucle obtenues ne sont pas intentionnelles. La qualité des cartes produites par NBV est la pire parmi les quatre algorithmes, et bien que les cartes finales produites à l'aide de NF semblent précises, les grandes déviations par rapport à cette estimation finale et les niveaux d'incertitude encourus pendant l'exploration ne sont pas réduits avant d'approcher l'achèvement de chaque session.

L'algorithme heuristique entraîne également une incertitude croissante lors de l'exploration, bien qu'il n'atteigne pas le même niveau que dans les algorithmes NF et NBV, et l'incertitude est réduite grâce à la sélection intentionnelle des fermetures de boucle. Cela peut être observé de manière la plus claire dans l'exécution 1 de la Figure 17, où à une distance de 100 le robot ferme intentionnellement la boucle pour réduire l'incertitude d'estimation. Différent de l'approche heuristique, qui recherche les fermetures de boucle uniquement dans des états fortement incertains, le

L'approche EM prend continuellement en compte l'incertitude de la carte, et les contraintes de fermeture de boucle sont entremêlées tout au long de la trajectoire dans les trois essais. Nous pouvons voir d'après la comparaison que l'EM maintient également une faible incertitude au cours des trois essais, tandis que le taux de couverture de la carte est compétitif par rapport aux autres approches.

VI. CONCLUSION ET TRAVAUX FUTURS

Dans cet article, nous avons présenté et évalué le concept d'utilisation de cartes virtuelles, composées de repères virtuels uniformément discrétisés, pour soutenir l'exploration autonome efficace d'environnements inconnus tout en gérant l'estimation d'état et l'incertitude de la carte. Notre algorithme d'exploration EM proposé, lorsqu'il est utilisé conjointement avec une architecture SLAM de pose à base de cadres clés sonar, équipe un robot sous-marin des capacités pour explorer de manière autonome un environnement sous-marin encombré tout en maintenant une carte précise, une estimation de pose et une estimation de trajectoire, en plus d'obtenir un taux de couverture efficace en temps. Les avantages du cadre proposé sont démontrés en simulation, et une preuve de concept qualitative est présentée au cours de plusieurs expériences d'exploration sous-marine réelles. Ces expériences représentent, à notre connaissance, la première instance d'exploration autonome d'un environnement extérieur réel, rempli d'obstacles, dans lequel un robot sous-marin (un BlueROV filaire que nous utilisons comme système de preuve de concept) intègre directement son processus SLAM et les prédictions basées sur ce processus dans sa prise de décision. Avenir




Fig. 18 : Trois essais d'exploration robotique du monde réel utilisant l'algorithme EM proposé dans l'environnement illustré à la Fig. 15. Chaque colonne montre les résultats d'un seul essai, chaque ligne affichant un instantané à une étape temporelle spécifique. La dernière ligne montre le terminus de chaque essai. Chaque sous-figure présente l'historique de pose du BlueROV et les contraintes de fermeture de boucle sur la carte d'occupation à gauche, avec la couverture et l'incertitude de pose indiquées à droite, tracées par rapport à la distance de déplacement.

le travail implique l'expansion de notre cadre pour prendre en charge la cartographie d'occupation tridimensionnelle basée sur le sonar.

REMERCIEMENTS

Nous tenons à remercier Arnaud Croux, Timothy Osedach, Sepand Ossia et Stephane Vannuffelen du Schlumberger-Doll Research Center pour leurs conseils et leur soutien qui ont été déterminants pour le succès des expériences de terrain décrites dans cet article. Nous remercions également la Prof. Carolyn Hunter de l'U.S. Merchant Marine Academy pour avoir facilité l'accès à la marina utilisée lors des expériences.

RÉFÉRENCES

- [1] C. Cadena, L. Carlone, H. Carrillo, Y. Latif, D. Scaramuzza, J. Neira, I. Reid, et J. J. Leonard, « Passé, présent et futur de la localisation et cartographie simultanées, vers l'ère de la perception robuste », *Transactions on Robotics, IEEE* vol. 32, no. 6, pp. 1309-1332, 2016.
- [2] J. Wang et B. Englot, « Exploration autonome avec maximisation de l'espérance », dans *les Actes du Symposium international sur la recherche en robotique (ISRR)*, 2017.
- [3] J. Wang, T. Shan, et B. Englot, « Cartes virtuelles pour l'exploration autonome avec pose SLAM », dans *les Actes de la Conférence internationale IEEE/RSJ sur les robots et systèmes intelligents (IROS)*, 2019, pp. 4899-4906.
- [4] R. Dubé, A. Gawel, H. Sommer, J. Nieto, R. Siegwart, et C. Cadena, « Un système SLAM multi-robots en ligne pour LiDARs 3D », dans *les Actes de la Conférence internationale IEEE/RSJ sur les robots et systèmes intelligents (IROS)*, 2017, pp. 1004-1011.
- [5] R. Dubé, D. Dugas, E. Stumm, J. Nieto, R. Siegwart, et C. Cadena, « Segmatch : reconnaissance de lieux basée sur les segments dans les nuages de points 3D », dans *les Actes de la Conférence internationale IEEE sur la robotique et l'automatisation (ICRA)*, 2017, pp. 5266-5272.
- [6] H. Feder, J. Leonard et C. Smith, « Navigation et cartographie adaptatives de robots mobiles », *The International Journal of Robotics Research*, vol. 18, no. 7, pp. 650-668, 1999.
- [7] R. Martinez-Cantin, N. de Freitas, J. Castellanos et A. Doucet, « Apprentissage actif de politiques pour la planification et l'exploration robotique sous incertitude », dans *Proceedings of Robotics: Science and Systems (RSS)*, 2007.
- [8] R. Sim et N. Roy, « Exploration robotique globale A-optimale en SLAM », dans *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, 2005, pp. 661-666.
- [9] V. Indelman, L. Carlone et F. Dellaert, « Planification dans le domaine continu : une approche généralisée de l'espace de croyance pour la navigation autonome dans des environnements inconnus », *The International Journal of Robotics Research*, vol. 34, no. 7, pp. 849-882, 2015.
- [10] B. Yamauchi, « Une approche basée sur les frontières pour l'exploration autonome », dans *Proceedings of the IEEE International Symposium on Computational Intelligence in Robotics and Automation (CIRA)*, juillet 1997, pp. 146-151.
- [11] B. J. Julian, S. Karaman et D. Rus, « Sur le contrôle basé sur l'information mutuelle du contrôle de robots à capteurs de distance pour des applications de cartographie », *The International Journal of Robotics Research*, vol. 33, no. 10, pp. 1375-1392, 2014.
- [12] S. Bai, J. Wang, F. Chen et B. Englot, « Exploration basée sur la théorie de l'information avec optimisation bayésienne », dans *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2016, pp. 1816-1822.
- [13] B. Charrow, S. Liu, V. Kumar et N. Michael, « Cartographie basée sur la théorie de l'information cartographie utilisant l'information mutuelle quadratique de Cauchy-Schwarz », dans *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, 2015, pp. 4791-4798.
- [14] M. Ghaffari Jadidi, J. Valls Miro, et G. Dissanayake, « Gaussian processus de cartographie autonome et d'exploration pour les robots mobiles à détection de portée »,
- [15] B. Charrow, G. Kahn, S. Patil, S. Liu, K. Y. Goldberg, P. Abbeel, N. Michael et R. V. Kumar, « Planification information-théorique avec optimisation de trajectoire pour cartographie dense Actes de 3D, dans *Robotics: Science and Systems (RSS)*, 2015.
- [16] A. Bircher, M. Kamel, K. Alexis, H. Oleynikova et R. Siegwart, « Planificateur de type horizon glissant « prochain-meilleur-vue » pour l'exploration 3D, dans *les actes de l'IEEE International Conference on Robotics and Automation (ICRA)*, 2016, pp. 1462-1468.
- [17] F. Bourgault, A. A. Makarenko, S. B. Williams, B. Grocholsky, et H. F. Durrant-Whyte, « Exploration robotique adaptative basée sur l'information », dans *les Actes de la Conférence internationale IEEE/RSJ sur les robots et systèmes intelligents (IROS)*, vol. 1, 2002, pp. 540-545.
- [18] A. A. Makarenko, S. B. Williams, F. Bourgault, et H. F. Durrant-Whyte, « Une expérience d'exploration intégrée », dans *les Actes de la Conférence internationale IEEE/RSJ sur les robots et systèmes intelligents (IROS)*, vol. 1, 2002, pp. 534-539.
- [19] C. Papachristos, S. Khatkhat, et K. Alexis, « Exploration à horizon glissant tenant compte de l'incertitude et cartographie à l'aide de robots aériens », dans *les Actes de la Conférence internationale IEEE sur la robotique et l'automatisation (ICRA)*, 2017, pp. 4568-4575.
- [20] C. Stachniss, G. Grisetti, et W. Burgard, « Exploration basée sur le gain d'information, en utilisant des filtres particuliers Rao-Blackwellisés », dans *les Actes de Robotics: Science and Systems (RSS)*, 2005, pp. 65-72.
- [21] R. Valencia, J. Valls Miró, G. Dissanayake, et J. Andrade-Cetto, « SLAM de pose active », dans *les Actes de la Conférence internationale IEEE/RSJ sur les robots et systèmes intelligents (IROS)*, 2012, pp. 1885-1891.
- [22] J. Vallvé et J. Andrade-Cetto, « SLAM de pose active avec RRT* », dans *les Actes de la Conférence internationale IEEE sur la robotique et l'automatisation (ICRA)*, 2015, pp. 2167-2173.
- [23] E. Vidal, J. D. Hernández, K. Istenič, et M. Carreras, « Planification de vues en ligne la planification de vues pour l'inspection de structures sous-marines inexplorées », *IEEE Robotics and Automation Letters*, vol. 2, no. 3, pp. 1436-1443, 2017.
- [24] N. Palomeras, N. Hurtós, E. Vidal, et M. Carreras, « Exploration autonome d'environnements sous-marins complexes à l'aide d'un planificateur probabiliste de prochaine meilleure vue », *IEEE Robotics and Automation Letters*, vol. 4, no. 2, pp. 1619-1625, 2019.
- [25] S. M. Chaves, A. Kim, et R. M. Eustice, « Planification d'échantillonnage opportuniste pour le SLAM visuel actif », dans *les Actes de la Conférence internationale IEEE/RSJ sur les robots et systèmes intelligents (IROS)*, 2014, pp. 3073-3080.
- [26] S. M. Chaves, J. M. Walls, E. Galceran, et R. M. Eustice, « Aversion au risque dans la planification en espace de croyance sous incertitude d'acquisition de mesures », dans *la Conférence internationale IEEE/RSJ sur les robots et systèmes intelligents 2015, IROS 2015*, pp. 2079-2086.
- [27] S. M. Chaves et R. M. Eustice, « Planification efficace avec l'arbre de Bayes pour le SLAM actif », dans *2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2016, pp. 4664-4671.
- [28] S. Suresh, P. Sodhi, J. Mangelson, D. Wettergreen et M. Kaess, « SLAM actif utilisant la saillance de sous-cartes 3D pour l'exploration volumétrique sous-marine », dans *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, 2020.
- [29] D. Koptikov et V. Indelman, « Mise à jour incrémentale de covariances à usage général et planification efficace dans l'espace de croyance via une propagation de graphe de facteurs arbre d'action » *The International Journal of Robotics Research*, vol. 38, no. 14, pp. 1644-1673, 2019.
- [30] D. Silver et J. Veness, « Planification Monte-Carlo dans de grands POMDP », dans *Advances in Neural Information Processing Systems*, vol. 23, 2010, pp. 2164-2172.
- [31] A. Somani, N. Ye, D. Hsu et W. S. Lee, « DESPOT : POMDP en ligne avec régularisation », dans *Advances in Neural Information Processing Systems*, vol. 26, 2013, pp. 1772-1780.
- [32] M. Kaess, H. Johannsson, R. Roberts, V. Ila, J. J. Leonard et F. Dellaert, « iSAM2 : Lissage incrémental et cartographie utilisant l'arbre de Bayes » *The International Journal of Robotics Research*, vol. 31, no. 2, pp. 216-235, 2012.
- [33] F. Dellaert et M. Kaess, « Square root SAM : Localisation et cartographie simultanées et cartographie via le lissage de l'information racine carrée », *The International Journal of Robotics Research*, vol. 25, no. 12, pp. 1181-1203, 2006.
- [34] H. Carrillo, I. Reid et J. A. Castellanos, « Sur la comparaison des critères d'incertitude pour le SLAM actif », dans *Actes de l'IEEE Conférence internationale sur la robotique et l'automatisation 2012, (ICRA)*, pp. 2080-2087.
- [35] M. Kaess et F. Dellaert, « Récupération de covariances à partir d'une racine carrée matrice d'information pour l'association de données » *Robotique et autonome Systèmes*, vol. 57, n° 12, pp. 1198-1210, 2009.
- [36] V. Ila, L. Polok, M. Solony, P. Smrz, et P. Zemcik, « Covariance rapide récupération dans les solveurs de moindres carrés non linéaires incrémentiels, dans *les actes de l'IEEE International Conference on Robotics and Automation (ICRA)*, 2015, pp. 4636-4643.
- [37] H. Li, F. Nashashibi et M. Yang, « Filtre d'intersection de covariances divisée: Théorie et son application à la localisation des véhicules, *IEEE Transactions sur les systèmes de transport* vol. 14, no. 4, pp. 1860-1871, intelligents, 2013.

- [38] P. J. Besl et N. D. McKay, « Une méthode pour l'enregistrement de la 3-D formes », *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 14, no. 2, pp. 239-256, 1992.
- [39] A. Elfes, « Navigation robotique : intègre perception, contraintes environnementales et exécution des tâches et exécution des tâches dans un cadre probabiliste », dans les actes de l'atelier international sur le raisonnement face à l'incertitude en robotique, 1995, pp. 91-130.
- [40] P. E. Hart, N. J. Nilsson et B. Raphael, « Une base formelle pour l'heuristique détermination des chemins de coût minimum », *IEEE Transactions on Systems Science and Cybernetics*, vol. 4, no. 2, pp. 100-107, 1968.
- [41] H. Carrillo, Y. Latif, M. L. Rodriguez-Arevalo, J. Neira et J. A. Castellanos, « Sur la monotonie des critères d'optimalité lors de l'exploration dans l'active SLAM », dans les actes de la IEEE International Conference on Robotics and Automation (ICRA), 2015, pp. 1476-1483.
- [42] M. A. Richards, *Fondamentaux du traitement du signal radar*. McGraw-Hill, 2005.
- [43] P. P. Gandhi et S. A. Kassam, « Analyse des processeurs CFAR dans un arrière-plan non homogène », *IEEE Transactions on Aerospace and Electronic Systems*, vol. 24, no. 4, pp. 427-445, juillet 1988.
- [44] M. Fischler et R. Bolles, « Consensus par échantillons aléatoires : un paradigme pour l'ajustement de modèle avec application à l'analyse d'images et à la cartographie automatisée », *Communications of the ACM*, vol. 24, no. 6, pp. 381-395, 1981.
- [45] J. G. Mangelson, D. Dominic, R. M. Eustice et R. Vasudevan, « Paire-de mesures cohérentes pour la maximisation d'ensemble de mesures dans la fusion de cartes multi-robots robuste », dans les actes de la IEEE International Conference on Robotics and Automation (ICRA), 2018, pp. 2916-2923.
- [46] A. Elfes, « Utilisation des grilles d'occupation pour la perception des robots mobiles et navigation », *Computer*, vol. 22, no. 6, pp. 46-57, juin 1989.
- [47] B.-J. Ho, P. Sodhi, P. Teixeira, M. Hsiao, T. Kusnur et M. Kaess, « Carte d'occupation virtuelle basée sur une grappe de sous-cartes SLAM pose graph et la planification dans des environnements 3D », dans les actes de l'IEEE/RISJ Conference internationale sur les robots intelligents et les systèmes (IROS), 2018, pp. 2175-2182.
- [48] A. Hornung, K. M. Wurm, M. Bennewitz, C. Stachniss et W. Burgard, « OctoMap : un cadre de cartographie probabiliste 3D efficace basé sur des octrees », *Autonomous Robots*, vol. 34, no. 3, pp. 189-206, 2013.
- [49] C. Rösmann, F. Hoffmann et T. Bertram, « Trajectoire intégrée en ligne-planification et optimisation de trajectoires dans des topologies distinctives », *Robotics and Autonomous Systems*, vol. 88, pp. 142-153, 2017.
- [50] F. Dellaert, « Graphes de facteurs et GTSAM : une introduction pratique », Georgia Institute of Technology, rapport technique GT-RIM-CP&R-2012-002, 2012.



Yewei Huang a obtenu une licence en systèmes d'information géographique et une maîtrise en géomatique et cartographie de l'université Tongji, Shanghai, Chine, respectivement en 2016 et 2019. Elle travaille actuellement vers le diplôme de doctorat au Département de génie mécanique, Stevens Institute of Technology, Hoboken, NJ, États-Unis.



John McConnell a obtenu une licence en ingénierie mécanique au SUNY Maritime College, État de New York, États-Unis, en 2015, et une maîtrise en ingénierie mécanique de Stevens Institute of Technology, Hoboken, NJ, États-Unis, en 2020. Il prépare actuellement le doctorat au département de génie mécanique de Stevens Institute of Technology, Hoboken, NJ, États-Unis. Avant de rejoindre Stevens, il a occupé des postes d'ingénierie chez l'American Bureau of Shipping, ExxonMobil et Duro UAS.




Tixiao Shan a obtenu une licence en génie mécanique et automatisation de l'Université de Qingdao, Qingdao, Chine, en 2011, une maîtrise en ingénierie mécatronique de l'Université de Shanghai, Shanghai, Chine, en 2014, et un doctorat en génie mécanique de Stevens Institute of Technology, Hoboken, NJ, États-Unis, en 2019. Entre 2019 et 2021, il a été associé postdoctoral au Massachusetts Institute of Technology, Cambridge, MA, États-Unis. Il est actuellement informaticien chez SRI International, Princeton, NJ, États-Unis.



Brendan Englot (S'11-M'13-SM'20) a reçu S.B., S.M., et doctorat en ingénierie mécanique du Massachusetts Institute of Technology, Cambridge, MA, États-Unis, en 2007, 2009 et 2012, respectivement.

Il a été chercheur scientifique au United Technologies Research Center, East Hartford, CT, États-Unis, de 2012 à 2014. Il est actuellement professeur associé au département de génie mécanique, Stevens Institute of Technology, Hoboken, NJ, États-Unis. Ses intérêts de recherche incluent la planification de mouvement,

planification, localisation et cartographie pour les robots mobiles, navigation autonome assistée par apprentissage, et robotique marine. Il est récipiendaire d'un prix CAREER de la National Science Foundation en 2017 et d'un prix Young Investigator de l'Office of Naval Research en 2020.



Jinkun Wang a obtenu une licence en sciences. Génie mécanique de l'Université des sciences et technologies de Chine, Hefei, Chine, en 2014, et master et doctorat en génie mécanique de Stevens Institute of Technology, Hoboken, NJ, États-Unis, en 2016 et 2020, respectivement. Il est actuellement Scientifique Applied chez Amazon Robotics à Louisville, CO, États-Unis.



Fanfei Chen a obtenu une licence en conception mécanique, fabrication et automatisation du Tongji Zhejiang College, Jiaxing, Chine, en 2014, et une maîtrise et un doctorat en génie mécanique de Stevens Institute of Technology, Hoboken, NJ, États-Unis, en 2016 et 2021, respectivement. Il est actuellement ingénieur en robotique senior chez Exyn Technologies à Philadelphie, PA, États-Unis.